

LUDWIG-MAXIMILIANS-UNIVERSITÄT MÜNCHEN
PROGRAMMING LANGUAGES AND ARTIFICIAL INTELLIGENCE



Titel der Arbeit

Ruben Triwari

Bachelorarbeit im Studiengang 'Informatik plus Mathematik'

Betreuer: Prof. Dr. Johannes Kinder

Mentor: Moritz Dannehl, M.Sc.

Ablieferungstermin: 7. Januar 2025

Zusammenfassung

In den letzten Jahren wurden große Fortschritte bei der Codierung von natürlichen Sprachen in reellwertigen Vektoren (engl. Embeddings) erzielt. Diese Arbeit verwendet diese Fortschritte, um aus den Informationen einer C-Quellcode-Funktion einen reellwertigen Vektor zu produzieren, welcher den Inhalt der Funktion codiert. Diese Vektoren können dann verwendet werden, um ein neuronales Netzwerk mittels überwachtem Lernen darauf zu trainieren, bei gegebener Funktion in Maschinensprache einen Vektor vorherzusagen, der den Inhalt der Funktion widerspiegelt. Die Embeddings werden zum einen aus Funktionsnamen, Funktionskommentaren und Code-Llama-Erklärungen [1] erstellt, indem der rohe Text, mittels *SentenceTransformer* [2] in einen Vektor umgewandelt wird. Zum anderen wurden Inferenzvektoren aus dem *Code2Vec* [3] Modell verwendet. Um die Qualität der Code-Llama-Vektoren, *Code2Vec*-Vektoren, Funktionskommentar-Vektoren und Funktionsnamen-Vektoren einzuordnen, wurden sie qualitativ und quantitativ verglichen. Zunächst wurde die beste Methode mittels einer Expertenbefragung identifiziert. Dabei stellte sich heraus, dass Code Llama die besten Embeddings produziert. Danach wurden die *Code2Vec*-Vektoren, Funktionskommentar-Vektoren und Funktionsnamen-Vektoren quantitativ mittels einer Formel mit den Code-Llama-Vektoren verglichen. Schließlich wurden die Code-Llama-Vektoren, *Code2Vec*-Vektoren, Funktionskommentar-Vektoren und Funktionsnamen-Vektoren qualitativ mittels *t-SNE* auf Gruppierungen untersucht. Nach qualitativer und quantitativer Auswertung konnten die Embeddings folgendermaßen absteigend nach Qualität angeordnet werden: Code-Llama-Vektoren, Funktionsnamen-Vektoren, Funktionskommentare-Vektoren und *Code2Vec*-Vektoren.

Abstract

In recent years, there have been great advances in encoding natural languages in real-valued vectors. This progress can be used to generate embeddings out of natural language information in C source code. These embeddings can then be used to train a neural network with supervised learning, which can predict a vector that reflects the content of the function, given a function in binary code. These embeddings are generated by the *SentenceTransformer* [2] using function names, function comments and Code Llama [1] explanations. In addition, we compare embeddings generated by the *Code2Vec* [3] model. To classify the quality of Code Llama vectors, *Code2Vec* vectors, function comment vectors and function name vectors, they were compared qualitatively and quantitatively. The best method was identified through an expert survey. It was found that Code Llama produced the best embeddings. The *Code2Vec* vectors, function comment vectors and function name vectors were compared quantitatively with the Code Llama vectors using a formula. Finally, the Code Llama, *Code2Vec*, function comment and function name vectors were compared qualitatively using *t-SNE*. After qualitative and quantitative evaluation, the embeddings can be ranked in descending order of quality as follows: Code llama vectors, function name vectors, function comment vectors and *Code2Vec* vectors.

Inhaltsverzeichnis

1	Einführung	1
1.1	Stand der Technik	2
1.2	Leistungen der Arbeit	2
1.3	Aufbau der Arbeit	3
2	Grundlagen	4
2.1	Maschinelles Lernen	4
2.1.1	Definition	4
2.1.2	Deep Learning	5
2.1.3	Überwachtes Lernen	6
2.1.4	Loss function	6
2.1.5	Backpropagation	6
2.1.6	Unüberwachtes Lernen	6
2.1.7	Reinforcement Learning	7
2.2	Semantische Vektorräume	7
2.2.1	Bag-of-Words	8
2.2.2	Word2Vec	8
2.2.3	Transformer	10
2.2.4	BERT	11
2.2.5	Sentence Transformer	12
2.3	Code Llama	14
2.4	Code2Vec	15
2.5	T-Distributed Stochastic Neighbor Embedding	16
3	Methodik	18
3.1	Datensatz	18
3.2	Datenpipeline	18
3.3	Stabilität von SentenceTransformer	19
3.4	Funktionskommentare	20
3.5	Code2Vec	20
3.5.1	Adaption auf C	20
3.5.2	Training	22
3.6	Funktionsnamen	22
3.7	Code-Llama-Erklärungen	23
4	Ergebnisse	24
4.1	Befragung von Experten	24
4.2	Quantitative Evaluierung	26
4.3	Qualitative Evaluierung	28
5	Diskussion	29
6	Fazit	33

A t-SNE Graphen	34
Literatur	36

1 Einführung

In den letzten Jahren wurden wichtige Fortschritte in der natürlichen Sprachverarbeitung erzielt, ein wichtiger Faktor war die Codierung von natürlicher Sprache in reellwertigen Vektoren (engl. embeddings). Die hochdimensionalen Vektoren codieren die Semantik der ursprünglichen Wörter oder Sätze. Diese hochdimensionalen Vektoren, die die Semantik von Wörtern oder Sätzen codieren, erlauben es, neuronale Netzwerke in diversen Anwendungsbereichen zu trainieren, wie beispielsweise *Spam Detection* [4]. Zu den bekanntesten Modellen, die natürliche Sprache in Vektoren abbilden, gehören *Word2Vec* [5], *WordPiece* [6] und *SentenceTransformer* [2].

Diese Fortschritte in der natürlichen Sprachverarbeitung, indem ein großer Faktor war, Wörter und Sätze in hochdimensionalen Vektoren zu codieren, dienen als Motivation, auch Assembler-Quellcode in einem Vektor zu codieren, der den Inhalt des Quellcodes widerspiegelt. Die resultierenden Vektoren, die den Inhalt des Binärcodes codieren, können dann wieder benutzt werden, um neuronale Netzwerke auf diverse Anwendungen zu trainieren, wie Beispielsweise *Binary Code-Similarity-Detection* [7], *Function-Boundary-Detection* [8], *Function-Type-Inference* [9], *Binary Code-Search* [10], Reverse Engineering [11], oder das Klassifizieren von Maleware in der Maschinensprache [12].

Um ein Modell mittels überwachtes Lernen zu trainieren, das Binärcode in Vektoren abbildet, welche den Inhalt des Binärcodes widerspiegelt, ist für jede Assembler-Funktion ein Vektor erforderlich, der den Inhalt der Funktion codiert. Dieser für das überwachte Lernen erforderlich Datensatz kann aus C-Quellcode erzeugt werden, falls ein Tool vorliegt welches aus C-Quellcode-Funktionen einen Vektor generiert, welcher den Inhalt der Funktion widerspiegelt. Um schließlich noch die Binärcode-Funktionen zu erhalten, werden die C-Quellcode-Funktionen kompiliert.

Das Ziel dieser Arbeit ist es, verschiedene Methoden zu vergleichen aus C Quellcode Vektoren zu generieren, die den Inhalt von dem ursprünglichen Quellcode codieren, mithilfe von Werkzeugen aus der natürlichen Sprachverarbeitung.

Der Prozess des Kompilierens reduziert Funktionen auf die für den Computer wesentlichsten Bausteine, dabei gehen viele Informationen verloren, wie Funktionsnamen, Variablennamen und Kommentare. Diese Informationen sind von großer Bedeutung, da sie Hinweise über die Funktionsweise und den Anwendungszweck der Funktion geben. Durch die Verwendung dieser Informationen könnte der Inhalt des Quellcodes besser in eine Vektor codiert werden.

Aufgrund der Tatsache, dass diese Informationen in der natürlichen Sprache sind, ist es sinnvoll, bewährte Werkzeuge aus der natürlichen Sprachverarbeitung zu verwenden, um diese in Vektoren zu codieren. Aus den resultierenden Vektoren kann schließlich ein Datensatz generiert werden, der ein neuronales Netzwerk darauf trainiert, Binärcode auf hochdimensionale, reellwertige Vektoren abzubilden, die den Inhalt des Quellcodes codieren.

1.1 Stand der Technik

CLAP (Contrastive Language Assembly Pre-training) [13] setzte Anfang 2024 einen neuen Stand der Technik, in *Binary Code-Similarity-Detection* mithilfe von natürlicher Sprachverarbeitung. Die Aufgabe bei *Binary Code-Similarity-Detection* besteht darin, die Ähnlichkeit zwischen zwei gegebenen Assemblercodes zu bestimmen.

Das CLAP-Modell ist aus zwei Teilen zusammengesetzt: einem Assembler-Encoder und einem Text-Encoder. Der Assembler-Encoder, der aus Assemblercode reellwertige Vektoren erzeugt, knüpft mit kleinen Änderungen an den vorherigen Stand der Technik von JTrans an. Der Text-Encoder ist eine neue Erweiterung, die darauf abzielt, den Text wieder in einen reellwertigen Vektor zu konvertieren. Wang et al. starten dabei mit einem Modell aus der natürlichen Sprachverarbeitung namens *SentenceTransformer* und trainieren dieses darauf, Assemblercode die passende Quellcodeerklärung zuzuordnen. Dabei erhalten sie die Quellcodeerklärungen durch ein Large Language-Model, wie beispielsweise Chat-GPT.

JTrans [7] baut auf einer Modellarchitektur aus der natürlichen Sprachverarbeitung namens Transformer [14] auf. Wang et. al. behandeln die einzelnen Assembler-Instruktionen als Wörter, um so die Transformer-Modellarchitektur anwenden zu können. Außerdem codieren sie Kontrollflussinformationen des Assembler-Codes in die Eingabe des Transformer-Modells. Mit diesem Ansatz erzielten sie im Jahre 2022 einen neuen Stand der Technik in *Binary Code Similarity Detection*.

1.2 Leistungen der Arbeit

Die hauptsächlichen Leistungen dieser Arbeit sind:

- ein Tool, das einen Datensatz mit Assemblercode und Vektoren, welche den Inhalt des Assemblercodes widerspiegeln, aus C-Quellcode und dem dazugehörigen Assemblercode generiert.
- eine qualitative Analyse durch *t-SNE* [15], die die Verwendung von Funktionskommentaren, Funktionsnamen, *Code-Llama*-Erklärungen [1] und *Code2Vec* [3] untersucht.
- eine quantitative Auswertung, die durch Befragung von Experten erfolgt, welche die Verwendung von Funktionskommentaren, Funktionsnamen, *Code-Llama*-Erklärungen und *Code2Vec* miteinander vergleicht.
- eine Formel, die die von den Funktionsnamen, Funktionskommentaren und *Code2Vec* erzeugten Vektoren, mit den von dem *Code-Llama*-Erklärungen vergleicht.

1.3 Aufbau der Arbeit

Kapitel 2 führt anfangs grundlegende Konzepte und Begriffe des maschinellen Lernens ein. Anschließend werden semantische Vektorräume in Bezug auf natürliche Sprache erläutert und die größten Fortschritte der letzten Jahre beschrieben. Am Ende werden noch *Code Llama*, *Code2Vec* und *t-SNE* vorgestellt, welche eine wichtige Rolle in dieser Arbeit spielen.

Die allgemeine Architektur des Tools und dessen Designentscheidungen werden im Kapitel 3 beschrieben. Es werden die Auswahl des C-Quellcodes, die Datenpipeline und die Stabilität des *SentenceTransformers* erläutert.

Kapitel 4, 5, 6 und 7 befassen sich mit den verschiedenen Methoden, Embeddings zu erzeugen. Also wie aus den Quellcodeinformationen über Funktionsnamen und -kommentare ein Vektor erstellt werden kann. Außerdem wird erläutert, wie mit *Code Llama* und *Code2Vec* Vektoren produziert werden können.

Die Ergebnisse werden in einer qualitativen und quantitativen Auswertung in Kapitel 8 vorgestellt. Zuerst wird durch eine Experten-Evaluierung die beste Methode identifiziert. Anhand dieser Einordnung wird überprüft, ob die Formel und Analyse durch *t-SNE* das Ergebnis der Experten-Evaluierung bestätigen.

Die Ergebnisse werden im Kapitel 9 reflektiert, eingeordnet und diskutiert. Es werden die Stärken und Schwächen jeder Methode dargestellt und diskutiert. Außerdem wird die vorgestellte Formel, um zwei Datenmengen zu vergleichen, diskutiert und Verallgemeinerungen präsentiert. Anschließend wird ein Ausblick gegeben, um weitere Anregungen für die weitere Arbeit in diesem Thema zu geben.

Im letzten Kapitel wird die gesamte Arbeit zusammengefasst und eine Anwendung meiner Arbeit motiviert.

2 Grundlagen

2.1 Maschinelles Lernen

Heutzutage ist maschinelles Lernen weitverbreitet und wird in nahezu jedem Bereich der Informatik verwendet. Maschinelles Lernen wird überall dort eingesetzt, wo eine analytische Lösung eines Problems zu aufwendig oder gar überhaupt nicht existiert. Maschinelles Lernen sucht nach einer Lösung, indem es aus den Daten ein Muster ableitet. Sind die Daten endlich, ist meist das resultierende Modell nur eine Approximation der gesuchten Lösung. In diesem Abschnitt wird zunächst maschinelles Lernen definiert und dann darauf aufbauend grundlegende Trainingsarten vorgestellt.

2.1.1 Definition

Die folgenden Definitionen sind entweder entnommen oder inspiriert von Kruse et al. [16] und Abu-Mostafa et al. [17]. Generell kann ein Problem, das mit maschinellem Lernen gelöst wird, wie folgt definiert werden:

Definition 1 Maschinelles Lernen

Sei X eine beliebige Input Menge, Y eine beliebige Output Menge, $f \in \{X \rightarrow Y\}$ die gesuchte Lösung des Problems, \mathbb{D} eine beliebige Menge aus gegebenen Datenpunkten, $H_1 \subset \{X \rightarrow Y\}$ ein Hypothesenraum, und $A_1 : \mathcal{P}(\{X \rightarrow Y\}) \times \mathcal{P}(\mathbb{D}) \rightarrow \{X \rightarrow Y\}$ ein Lernalgorithmus. Dann ist das Ziel, bei gegebenen Daten, den Hypothesenraum H_1 und den Lernalgorithmus A_1 so zu wählen, sodass

$$A_1(H_1, \mathbb{D}) \approx f.$$

Maschinelles Lernen ist also die Suche nach einem Lernalgorithmus und Hypothesenraum, der dann in Kombination mit gegebenen Daten die Lösung approximiert. Dabei ist hervorzuheben, dass der Datensatz das Herzstück jeder Problemstellung im Bereich des maschinellen Lernens ist. Wenn der Datensatz zu klein oder überhaupt nicht repräsentativ für das gegebene Problem ist, wird der Lernalgorithmus die falschen Muster erkennen und dadurch eine fehlerhafte Approximation erzeugen.




Abbildung 2.1: Herangehensweise um mit maschinellen Lernen ein Problem zu lösen

In der Figur 2.1 ist die Problembeschreibung noch einmal bildlich dargestellt. Beachtenswert ist, dass die Datenpunkte nicht immer in Abhängigkeit mit $f : X \rightarrow Y$ stehen. Beispielsweise können die Datenpunkte einfach nur aus den Eingabewerten bestehen: $\mathbb{D} = \{x_1, x_2, x_2, \dots, x_n\} \subset X$. Die Struktur des Datensatzes kann sehr unterschiedlich sein, das hängt auch mit unterschiedlichen Lernmethoden zusammen.

2.1.2 Deep Learning

Vor der Betrachtung der Lernmethoden wird kurz auf Deep Learning eingegangen. Deep Learning ist ein neuronales Netzwerk, das über mehrere Layer zwischen Input und Output Layer verfügt. Zunächst einmal müssen wir neuronale Netzwerke definieren:

Definition 2 *Neuronales Netzwerk*

Ein neuronales Netzwerk (NN) ist eine Funktion $N : \mathbb{R}^q \rightarrow \mathbb{R}^p$, wobei $q \in \mathbb{N}$ die Anzahl der Inputs und $p \in \mathbb{N}$ die Anzahl der Outputs ist. Sei $(L_i)_{i \in \{1, \dots, n\}}$ die Layer, $(K_i^l)_{l=1, \dots, n, i=1, \dots, r_l}$ die Knoten im jeweiligen Layer $l \in \{1, \dots, n\}$ und $r_l \in \mathbb{N}$ die Anzahl der Knoten im Layer L_l . Jeder Knoten im Layer L_l ist mit jedem Knoten im Layer L_{l+1} verbunden, mit $l \in \{1, \dots, n-1\}$. Jede Verbindung besitzt ein Gewicht $W_{i,j}^l$, wobei $l \in \{1, \dots, n-1\}$ und das Gewicht der Verbindung $K_i^l \rightarrow K_j^{l+1}$ zugeordnet ist. Daraus ergibt sich eine Familie von Matrizen $(W_l)_{l=1, \dots, n-1}$, wobei $W_l \in \mathbb{R}^{r_l \times r_{l+1}}$. Nun hat jeder Layer noch einen sogenannten Bias $(B_l)_{l=2, \dots, n}$, dieser ist ein Zeilenvektor $B_l \in \mathbb{R}^{r_l}$. Schließlich braucht jeder Knoten eine Aktivierungsfunktion, das heißt für jeden Layer gibt es r_l Funktionen: $(F_l)_{l=1, \dots, n}$, mit $F_l \in \{\mathbb{R} \rightarrow \mathbb{R}\}^{r_l}$. Es ist hilfreich die Funktionsanwendung auch für den Vektor F_l zu definieren: Sei $x \in \mathbb{R}^{r_l}$, dann setze

$$F_l(x) := \begin{pmatrix} f_1(x_1) \\ \vdots \\ f_{r_l}(x_{r_l}) \end{pmatrix}.$$

Dann ist die Funktion $N : \mathbb{R}^q \rightarrow \mathbb{R}^p$ wie folgt definiert:

$$N(x) = h_1(x)$$

,wobei

$$h_l : \mathbb{R}^{r_l} \rightarrow \mathbb{R}^{r_{l+1}}$$

$$h_l(x) = \begin{cases} h_{l+1}(F_{l+1}(W_l x + B_{l+1})) & , \text{if } l < n \\ x & , \text{sonst} \end{cases}.$$

Wir bezeichnen L_1 als Input-Layer, L_n als Output-Layer und L_i , mit $i \in \{2, \dots, n-1\}$, als Hidden Layer.

Nun mit Neuronalen Netzwerken definiert, kann Deep Learning definiert werden:

Definition 3 *Deep Learning*

In Deep Learning besitzt ein beliebiges neuronales Netzwerk $n > 3$ Layer, also ein Input-Layer, ein Output-Layer und mehr als ein Hidden-Layer.

Deep Learning ist ein Hypothesenraum, da alle neuronalen Netzwerke höherdimensionale reellwertige Funktionen sind, gilt für den Hypothesenraum:

$$H_{DL} = \{\mathbb{R}^n \rightarrow \mathbb{R}^k\}, \text{ wobei } n, k \in \mathbb{N}$$

2.1.3 Überwachtes Lernen

Das überwachte Lernen ist die am häufigsten verwendete Trainingsmethode und ist daher auch die wichtigste. Beim überwachten Lernen existiert im Datensatz für einen gegebenen Input die zu erlernende korrekte Ausgabe. Also haben die Trainingsdaten folgende Form:

$$\mathbb{D} = \{(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots, (x_n, y_n)\} \subset X \times Y.$$

Ein Beispiel für diesen Ansatz ist die Bilderkennung, bei der ein Vektor mit Grauwerten und ein Label bzw. eine Bezeichnung für das Bild verwendet werden.

Beispiel 2.1 Sei $X = \mathbb{R}^{4096}$ und $Y = \{\text{Katze}, \text{Hund}, \text{Auto}\}$, dann könnte der Datensatz wie folgt aussehen:

$$\mathbb{D} = \left\{ \left(\begin{pmatrix} 0.2 \\ 0.9 \\ 0.5 \\ \vdots \end{pmatrix}, \text{Hund} \right), \left(\begin{pmatrix} 0.1 \\ 0.1 \\ 0.6 \\ \vdots \end{pmatrix}, \text{Hund} \right), \left(\begin{pmatrix} 0.6 \\ 0.7 \\ 0 \\ \vdots \end{pmatrix}, \text{Katze} \right), \dots, \left(\begin{pmatrix} 0.4 \\ 0.3 \\ 0.9 \\ \vdots \end{pmatrix}, \text{Auto} \right) \right\}$$

2.1.4 Loss Function

2.1.5 Backpropagation

Der entscheidende Aspekt ist, dass wir das richtige Verhalten unseres Modells kennen und deshalb direkt wissen, wenn es Fehler macht. Beim selbst-überwachten Lernen werden die richtigen Lösungen aus gegebenen Daten generiert. Bei vielen anderen Arten ist dieser Aspekt, der sehr natürlich erscheint, nicht selbstverständlich.

2.1.6 Unüberwachtes Lernen

Das unüberwachte Lernen ist der Extremfall, da der Lernalgorithmus ausschließlich die Input-Werte erhält.

$$\mathbb{D} = (x_1, x_2, x_3, \dots, x_n) \subset X$$

Der Lernalgorithmus erhält keine Hinweise darauf, was richtig oder falsch ist. Unüberwachtes Lernen ist eine Methode, um in Daten Strukturen und Muster zu identifizieren. Ein Beispiel ist die Cluster-Analyse, hier bekommt der Lernalgorithmus eine Menge von Daten und gruppiert diese in

Teilmengen. In der Abbildung 2.3 ist ein Beispiel für das Resultat einer möglichen Cluster-Analyse dargestellt.




Abbildung 2.2: Cluster Analyse angewendet auf 2-dimensionale Daten aus [18].

2.1.7 Reinforcement Learning

Das Reinforcement Learning ist nicht so extrem wie das unüberwachte Lernen. Bei diesem Paradigma liegen dem Lernalgorithmus zwar nicht die korrekten Output-Werte vor, aber der Lernalgorithmus erhält für jeden vorhergesagten Wert eine Rückmeldung, wie erwünscht dieser Wert ist. Ein Beispiel ist ein Modell, das mittels eines Lernalgorithmus darauf trainiert wird, ein Videospiel zu gewinnen. Der Lernalgorithmus bekommt ein Abbild von der Umgebung und gibt dem Spiel einen Input, welcher eine Aktion zufolge hat. Falls nun die Aktion dazu beiträgt, den Spieler in eine gute Position zu bringen oder gar das Spiel zu gewinnen, bekommt die Aktion eine positive Bewertung, andernfalls eine negative.

Die Problemstellung im maschinellen Lernen ist allgemein formuliert und abstrakt. Dies ist der Grund, warum maschinelles Lernen in vielen unterschiedlichen Bereichen eingesetzt werden kann. Einer der Bereiche ist die natürliche Sprachverarbeitung (engl. natural language processing), was uns zum nächsten Begriff führt. Natürliche Sprachverarbeitung wird im Folgenden mit NLP abgekürzt.

2.2 Semantische Vektorräume

Das semantische Codieren von natürlicher Sprache in einem Vektorraum ist ein bedeutsames Problem in NLP [5], [2]. Der resultierende Vektorraum kann für verschiedene Problemstellungen (engl. downstream tasks) verwendet werden. Ein Beispiel ist die Klassifizierung von Spam Nachrichten [4]. Folgende Definitionen werden in dieser Arbeit für semantische Vektorräume verwendet.

Definition 4 (Semantischer Vektorraum)

Ein semantischer Vektorraum stellt Objekte als reelle Vektoren dar, in einer Weise, dass ähnliche Objekte im projizierten Vektorraum einen geringen Abstand zueinander haben.

Hierfür ist es erforderlich vorher zu definieren, inwiefern zwei Objekte ähnlich sind und welchen Abstandsbegriff man im Vektorraum wählt. Der Begriff semantischer Vektorraum für natürliche Sprache heißt hier, dass ähnliche Wörter, also Wörter mit ähnlicher Bedeutung im projizierten Vektorraum, einen geringen Abstand zueinander haben. Wir werden die Vektoren im Folgenden als Embeddings bezeichnen. In einem idealen semantischen Vektorraum würde die Beziehung gelten, die in Figur 2.4 dargestellt wird.




Abbildung 2.3: Optimaler fiktiver semantischer Vektorraum

2.2.1 Bag-of-Words

Ein natürlicher Ansatz ist es, jedem Wort im vorliegenden Text eine Zahl zuzuordnen. Dadurch können sowohl die Häufigkeit eines Wortes als auch die Sätze, in denen ein bestimmtes Wort vorkommt, effizient gefunden werden. Die Bedeutung eines Wortes ist hier komplett unabhängig von der Wahl der zugewiesenen Zahl. Das führt dazu, dass sogar Synonyme einen hohen Abstand haben können.

Beispiel 2.2 Sei $T = \{\text{Input}, \text{Mann}, \text{Frau}, \text{Eingabe}\}$ eine Menge von Wörtern, dann ist die Zuordnung zu dem Vektorraum \mathbb{N}^1 wie folgt:

$$\text{Input} \rightarrow 1, \text{Mann} \rightarrow 2, \text{Frau} \rightarrow 3, \text{Eingabe} \rightarrow 4.$$

Obwohl Eingabe und Input semantisch sehr ähnlich sind, haben sie hier einen sehr unterschiedlichen Wert.

2.2.2 Word2Vec

Im Jahr 2013 veröffentlichten Mikolov et al. [5], zwei Modellarchitekturen, mit der ein neuronales Netzwerk effizient lernen kann, semantische Embeddings zu produzieren. Mikolov et al. haben eine Implementierung veröffentlicht die sie *Word2Vec*¹ genannt haben. In beiden Architekturen besteht das neuronale Netzwerk aus einem Hidden Layer, der nach dem Training die reellwertigen Vektorrepräsentationen enthält. Der Aufbau bei beiden Modellen ist in Figur 2.5 dargestellt. Es ist zu beachten, dass der Hidden Layer keine Aktivierungsfunktion besitzt, da er nur als lineare Transformation von einer One-Hot-Codierung zu einem reellwertigen Vektor dient.

¹<https://code.google.com/archive/p/word2vec/>

One-Hot-Codierung produziert für jedes aus n Wörtern einen Vektor $v \in \{0, 1\}^n$. Dieser Vektor ist an einer Stelle mit einer Eins und sonst überall mit einer Null versehen. Jede Position, an der eine Eins ist, gibt es nur einmal und codiert so durch die Position ein Wort. Der Output-Layer hat als Aktivierungsfunktion einen Softmax, der Softmax gibt Werte zwischen 0 und 1 zurück. Der Output ist also ein Vektor $v \in (0, 1)^n$, daraus kann dann entweder je nach Anwendung durch One-Hot-Codierung ein oder mehrere Wörter abgeleitet werden.




Abbildung 2.4: Architektur des neuronalen Netzwerks von Word2Vec

Es gibt nun zwei unterschiedliche Strategien, das neuronale Netzwerk zu trainieren. Die erste ist Skip-Gram, gegeben ein Wort, soll das Modell die naheliegenden Wörter vorhersagen. Das heißt, es soll einem Wort einen richtigen Kontext zuordnen. Das Modell wird dadurch die Fähigkeit entwickeln, Wörter mit ähnlichen Kontexten ähnlichen Embeddings zuzuordnen.

Die zweite Methode ist Continuous Bag-of-Words (CBOW), bei der das Modell den Kontext eines Wortes erhält, das heißt es erhält die Wörter die links und rechts von dem Wort sind als Input. Die Aufgabe besteht nun darin das Wort vorherzusagen welches zum gegebenen Kontext passt. Folglich soll das Wort, das zu dem gegebenen Kontext passt, vorhergesagt werden. Da ähnliche Wörter ähnliche Kontexte haben, neigt das Modell dazu, ähnliche Outputs für ähnliche Kontexte zu lernen. Die Word2Vec-Embeddings sind dann ähnlich, wenn ihre Kontexte, in denen sie verwendet werden, ähnlich sind. Die Kontexte haben eine feste Größe, die am Anfang ausgewählt wird. Wenn die Kontextgröße zu klein gewählt wird, kann es passieren, dass das Wort mit inhaltslosen Wörtern assoziiert wird, wie z.B. Artikel oder Präpositionen. Wenn die Kontextgröße zu groß ist, können unterschiedliche Kontexte verschwimmen und ungenaue Ergebnisse entstehen. Folglich hat die Kontextgröße einen entscheidenden Einfluss auf den Erfolg des Modells. Vaswani et al. lösen das Kontextproblem durch die Transformer-Modellarchitektur [14].

2.2.3 Transformer

Die Transformer-Architektur [14] ist ein Meilenstein im NLP Bereich. Die vorgestellte Deep Learning Architektur bildet die Basis für BERT, *SentenceTransformer* und Large Language-Models (wie z.B. Chat-GPT). Das Modell wurde ursprünglich entwickelt, um bei einem gegebenen Satz einen sinnvollen neuen Satz zu generieren. Die Downstream Task auf die eine Implementierung der Architektur trainiert wurde, ist das Übersetzen von Englisch zu Deutsch und von Englisch zu Französisch. Der Transformer kann jedoch wieder zur Erzeugung semantischer Embeddings verwendet werden, wie im Abschnitt zum *SentenceTransformer* erläutert wird.




Abbildung 2.5: Transformer-Architektur stark vereinfacht

Die Architektur hat zwei große Blöcke, die in der Abbildung 2.6 zusehen sind. Der erste Block ist der Encoder, dieser erhält die Eingabe. Beim Übersetzen wäre das der zu übersetzende Text. Der Encoder codiert den Input in semantische Embeddings und gibt an, wie wichtig jedes Wort in dem Satz für ein anderes gegebenes Wort ist. Bei dieser Architektur gibt es keine Kontextgröße, sondern der Kontext ist die gesamte Eingabe. Somit ist das Problem der Kontextgröße aus dem letzten Abschnitt gelöst. Der Encoder bestimmt, welche Wörter wichtig sind und welche eher unwichtig sind in Bezug auf ein gegebenes Wort. Der Decoder erhält den von ihm selbst produzierten Output sowie das Ergebnis des Encoders, um das nächste Wort zu generieren. Außerdem startet dieser mit einem konstanten Start-Embedding und um die Generierung zu stoppen, gibt er selbst ein konstantes Stopp-Embedding aus. Insbesondere ist es möglich, dass mehrere Encoder und Decoder gleichzeitig hintereinander geschaltet werden können.

Die Architektur ist in Abbildung 2.7 dargestellt. Im Folgenden werden die wichtigsten Bestandteile der Abbildung erläutert. **Input-Embedding** gibt dem Input, der in Textform vorliegt, eine Vektorrepräsentation. Danach wird auf dem Vektor ein **Positional Encoding** darauf addiert. Der Transformer verarbeitet alle Wörter parallel, deswegen geht die Positionsinformation verloren. Um diese Information trotzdem im Vektor zu codieren, wird für jede Position ein einzigartiger Vektor auf das Wort-Embedding addiert. Im Block **Add & Norm** werden zwei Inputs addiert und dann normalisiert, damit die Werte in dem Modell nicht zu groß werden. Feed Forward ist ein neuronales Netzwerk mit zwei Layern. Alle Wort-Embeddings werden nacheinander und identisch in das Netzwerk eingegeben. Der erste Input-Layer hat als Aktivierungsfunktion ein Softmax und der

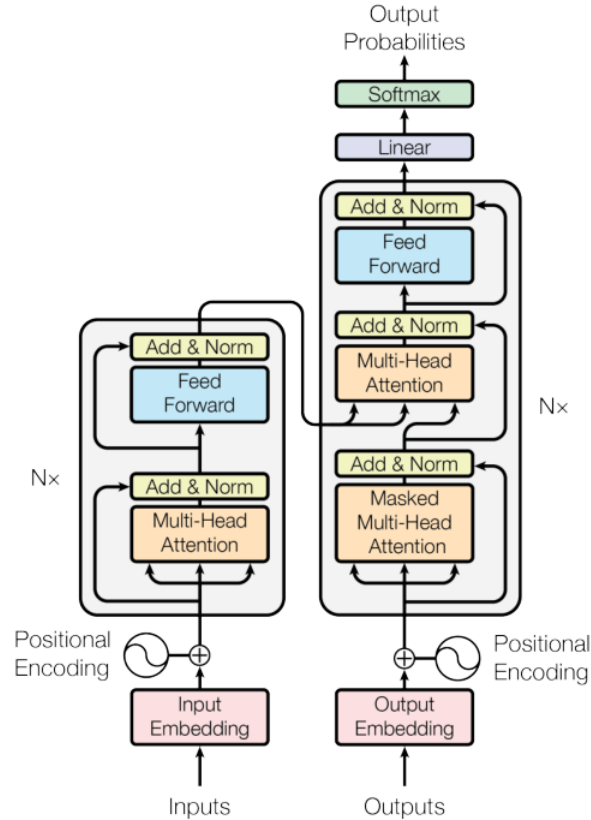


Abbildung 2.6: Transformer-Architektur entnommen aus [14]. Der linke Block ist der Encoder und der rechte Block der Decoder.

zweite hat die Identitätsfunktion. Dann gilt für das Netzwerk:

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2.$$

Der **Linear Block** ist wieder ein neuronales Netzwerk, mit allen Aktivierungsfunktionen: $f_{i,j}(x) = x$. Das **Multi Head-Attention** Modul ist der wohl wichtigste Bestandteil der Architektur. Dieses gibt die Korrelation zwischen einem Wort und allen Restlichen im Input aus. Der gesamte Input wird als Kontext betrachtet, aber das Modell lernt, auf welche Wörter es im Kontext viel oder wenig Aufmerksamkeit schenken soll. Das **Masked Multi Head-Attention** Modul ist nur beim Trainieren anders als das Multi Head-Attention-Modul. Beim Trainieren ist der Input des Decoders bereits der Satz, den das Modell vorhersagen soll. Daher müssen alle Wörter, die es noch nicht vorhergesagt hat, verdeckt (engl. masked) werden.

2.2.4 BERT

Das BERT-Modell [19] ist ein wichtiger Meilenstein im NLP-Bereich und kann als eines der ersten Large Language-Models betrachtet werden. Das Modell verbessert die Transformer-Architektur, indem es die Token-Embeddings verbessert, zwei neue Trainingsaufgaben einführt und ausschließlich Encoder verwendet. In Abbildung 2.8 ist der Token-Embedding-Prozess abgebildet, der im




Abbildung 2.7: Token-Embedding-Prozess entnommen aus [19].

Folgenden näher beschrieben wird. Zunächst ist es notwendig zu erläutern, was ein Token ist. Ein Token ist in diesem Fall ein Wort, aber generell die kleinste bedeutungstragende Einheit im Sprachsystem. Die Aufteilung eines Textes in Tokens vereinfacht die weitere Verarbeitung.

Das BERT Modell kombiniert drei unterschiedliche Informationen in Vektorform, um noch bessere Token-Embeddings als die Token-Embeddings von dem Transformer zu generieren. BERT verwendet *WordPiece* [6], um die rohen Tokens in Vektoren umzuwandeln. Auf diese werden nun ein Segment-Embedding und schließlich die Position-Embeddings addiert. Das **Segment-Embedding** codiert die Information, welche Tokens zu welchen Satz gehören. Das **Position-Embedding** codiert die globale sequenzielle Position im Input.

Die beiden unterschiedlichen Trainingsaufgaben stellen das wichtigste Puzzleteil dar. Während der Transformer die Tokens von links nach rechts vorhersagt, wird BERT darauf trainiert, Wörter vorherzusagen, die auf beliebiger Position fehlen. Dadurch erhält das Modell Zugang zu dem Kontext, der sich links und rechts von dem zu prädizierenden Token befindet. Diese Trainingsform wurde **Masked Language-Modeling** von Wu et al. benannt. Bei diesem Verfahren werden 15% der Input-Token entweder durch das [Mask] Token oder durch einen zufälligen anderen Token ersetzt. Dabei bleiben 10% der Token, die maskiert werden sollten, unverändert. Weitere 10% der Token, die maskiert werden sollten, werden durch ein zufälliges anderes Token ersetzt, während die restlichen 80 % durch das [Mask] Token ersetzt werden.

Die zweite Trainingsaufgabe ist **Next Sentence-Prediction** (NSP), bei dieser Aufgabe soll das BERT Modell bei der Eingabe von zwei Sätzen entscheiden, ob diese sequenziell nacheinander kommen oder nicht. Bei der einen Hälfte der Daten handelt es sich um zwei Sätze, die nacheinander auftreten. Bei der anderen Hälfte der Daten handelt es sich um zufällige, nicht sequenzielle Sätze. Zur Inferenz des Modells, ob die Sätze nacheinander kommen oder nicht, wird ein Token [cls] eingeführt, welches beim Input immer an erster Stelle steht. Der erste Output-Vektor des BERT-Modells ist das Ergebnis des [cls] Tokens und wird verwendet, um den Output isNext oder notNext zu produzieren.

Nach dem Training erhält man aus dem BERT-Modell für jeden Input-Vektor genau einen Output-Vektor. Die Output-Vektoren codieren nun die Input-Tokens und können weiter verwendet werden, um mit wenig Aufwand ein Modell für bestimmte Probleme in NLP zu kreieren.

2.2.5 Sentence Transformer

Das Sentence-BERT-Modell [2] ist der aktuelle Stand der Technik im semantischen Codieren von natürlicher Sprache in einem Vektorraum. Die Implementierung ist unter dem Namen *Sen-*




Abbildung 2.8: SBERT-Architektur entnommen aus [2]. Beide BERT-Modelle teilen sich dieselben Gewichte.

*sentenceTransformer*² von Reimers et al. bekannt. Die Motivation hinter Sentence-BERT (SBERT) ist das effiziente semantische Vergleichen von zwei Sätzen. Wenn man mit BERT herausfinden möchte, wie semantisch ähnlich zwei gegebene Sätze sind, dann ist es erforderlich, dass beide Sätze als Input in das Modell eingeben. Das heißt, wenn die Ähnlichkeit von allen n Sätzen jeweils zueinander herausgefunden werden soll, gibt es $\frac{n(n-1)}{2}$ Eingaben in das BERT Modell. Bei SBERT kann dagegen jeder Satz einzeln eingegeben werden und der resultierende Output ist dann ein semantischer Vektor. Um die semantische Ähnlichkeit zwischen zwei Vektoren zu erhalten, müssen beide Vektoren lediglich in eine zu wählende Metrik eingesetzt werden. Dies ermöglicht es, die semantische Ähnlichkeit zwischen zwei Vektoren effizient zu berechnen.

Die Modellarchitektur von SBERT wird als **Siamese Neural Network** bezeichnet, da zwei unterschiedliche BERT-Modelle verwendet werden, um beide Sätze in einen Vektor umzuwandeln, aber beide Modelle teilen sich die Gewichte. In der Abbildung 2.9 ist die Siamese Neural Network zusehen.

Die Output-Vektoren von den zwei BERT-Modellen werden schließlich in ein Pooling-Modul eingegeben. **Pooling** ist das zusammenfassen von vielen Vektoren in eine geringere Anzahl von Vektoren oder Dimensionen. In diesem Fall werden die n Output-Vektoren von den zwei BERT-Modellen in einen einzigen Output-Vektor transformiert. Das Default Pooling von dem *SentenceTransformer* ist der Mittelwert, d.h. auf alle Einträge der Output-Vektoren von den BERT-Modellen wird das arithmetische Mittel angewendet. Daraus erhält man einen Vektor mit den jeweiligen gemittelten BERT-Output-Vektoren.

Das BERT Modell wird vorher an die spezielle Aufgabe angepasst, zwei Vektoren semantisch zu vergleichen. Dafür wird der SNLI Datensatz verwendet, dieser beinhaltet immer zwei Sätze mit drei möglichen Labels: *contradiction*, *neutral*, und *entailment*. SBERT soll für zwei Sätze vorhersagen, ob sie sich inhaltlich widersprechen, neutral zueinander sind oder ob der eine Satz eine Fortsetzung des anderen ist. Daraus lernt das Modell, ein semantisches Verständnis für Sätze zu erlangen.

Beim Training wird zur Ermittlung der Label-Vorhersage ein neuer Output-Vektor kreiert, indem die beiden Pooling-Output-Vektoren und ihre Differenz miteinander konkateniert werden. Anschließend

²<https://sbert.net>

wird dieser neue Output-Vektor mit einer Matrix, welche durch das Training erlernte Gewichte enthält, multipliziert, sodass ein Vektor mit drei Dimensionen entsteht. Danach wird der Softmax auf alle Einträge des finalen Output-Vektors angewendet. Die Position in dem Vektor mit dem höchsten Wert wird schließlich dem zugehörigen Label zugeordnet. Mathematisch: Sei $W \in \mathbb{R}^{3 \times (2 \cdot n + 1)}$ die Matrix, die die Gewichte enthält, $u, v \in \mathbb{R}^n$ die Output-Vektoren von dem Pooling-Modul, concat die Funktion die drei Vektoren konkateniert und $|\cdot|$ eine beliebige Norm, dann

$$o_i = \text{softmax}((W \cdot \text{concat}(u, v, |u - v|))_i).$$

Nachdem Training bei der Inferenz wird der Vektor, nachdem Pooling-Modul als Output-Vektor ausgegeben. SBERT liefert uns also ein Tool, um Sätze semantisch in einem Vektorraum abzubilden, welches sich in späteren Kapiteln als sehr hilfreich herausstellt.

2.3 Code Llama

Die *Code-Llama*-Familie an Large Language-Models wurde von Rozière et al. im Jahre 2024 entwickelt [1]. **Large Language-Models** sind Modelle, die auf einer großen Menge von Daten trainiert wurden, welche sich darin auszeichnen, natürliche Sprache verstehen sowie generieren zu können und deswegen in der Lage sind, eine Vielzahl von Aufgaben im NLP-Bereich zu lösen.

Code Llama ist das auf Programmiersprachen spezifische Aufgaben optimierte vorangegangene Llama-2-Modell. Das LLama-2-Modell wird, um zum resultierenden Code Llama zu kommen, erneut auf einem neuen Datensatz trainiert. Dieser besteht aus drei verschiedenen Kategorien von Daten. Der größte Teil im Datensatz, mit 85% wurde zufällig aus einen 859 GB großen Datensatz, aus Programmiersprachen spezifischen Aufgaben entnommen, indem das Modell darauf trainiert wird, fehlende Programmzeilen in einer vergebenen Lücke zu füllen. Dabei kann es sich um Programmcode, aber auch um Kommentare handeln. Der zweitgrößte Teil im Datensatz, mit 8% wurde zufällig aus einen 78 GB großen Datensatz entnommen, welcher aus natürlicher Sprache besteht, in der es um Programmcode geht. Dieser Teil beinhaltet Diskussion über Quellcode sowie Fragen und Antworten, welche sich auf Quellcode beziehen. Der kleinste Teil im Datensatz mit 7% wurde zufällig aus einen 3.5 TB großen Datensatz entnommen und besteht aus beliebiger natürlicher Sprache, damit das Modell seine alten Fähigkeiten erhält.

Das LLama-2-Modell ist eine Verbesserung des Llama-Modells. Dieses wurde auf neueren Daten trainiert und verwendet 40% mehr Tokens, die Llama-Famillie besitzt je nach Modell 1.0 – 1.4 Billionen Tokens und die gesamte Llama-2-Famillie besitzt 2.0 Billionen. Außerdem wurde die Kontextlänge verdoppelt und es gab eine Veränderung in der Llama-Transformer-Architektur. In den Attention-Modulen werden zwei Werte, die normalerweise immer wieder berechnet werden, geteilt, was bedeutet, dass jedes Attention-Modul Zugriff auf die gleichen Werte hat. Dies führt zu geringfügig schlechteren Ergebnissen, jedoch zu einer deutlichen Leistungssteigerung.

Das Llama-Modell wiederum besteht aus einer Decoder-only-Transformer-Architektur. Der **Decoder-only-Transformer** besteht lediglich aus Decoder-Transformer-Blöcken, wie der Name bereits vermuten lässt. Bei dieser Architektur ist der anfängliche Input des Decoders die Eingabe des Nutzers. Auf diese Eingabe wird dann immer wieder das neu generierte Token drauf konkateniert. Auf diese Weise wird die Eingabe nicht explizit von dem bereits generierten getrennt, sondern beides wird als gleicher Kontext verwendet.

Das Besondere an Llama ist, dass es nur auf frei verfügbaren Daten trainiert wurde und dass das Mo-




Abbildung 2.9: *Code2Vec*-Architektur entnommen aus [3]

dell Open Source ist. Der Datensatz besteht aus English Common Crawl [67%], C4 [15%], Github [4.5%], Wikipedia [4.5%], Gutenberg and Books3 [4.5%], ArXiv [2.5%], und Stack-Exchange [2%].

Code Llama ist eine Open Source-Software, die unter allen verfügbaren Modellen am besten in multilingualen Benchmarks abschneidet. Multilingual bedeutet die Verwendung mehrerer Programmiersprachen. Diese Eigenschaften machen es sehr geeignet für diese Arbeit.

2.4 Code2Vec

Code2Vec ist eine im Jahre 2018 von Alon et al. entwickelte Modellarchitektur, die Quellcode in einen semantischen Vektor kodiert [3]. Nach den Erfolgen in NLP, natürliche Sprache in semantische Vektoren zu kodieren, entstand der Wunsch, auch Quellcode in semantischen Vektoren abzubilden. Mit diesen Vektoren können dann wieder viele verschiedene Aufgaben gelöst werden. Das motivierende Beispiel bei *Code2Vec* ist die Vorhersage eines sinnvollen Namens für eine Funktion. Die Architektur, welche in Abbildung 2.10 dargestellt ist, wird im Folgenden erläutert. Alon et al. fanden heraus, dass eine geeignete Darstellung von Quellcode als ein mathematisches Objekt ein abstrakter Syntaxbaum ist. Dieser erhält die strukturellen Zusammenhänge zwischen den Tokens und kann gut in einen Vektor codiert werden. Die Input-Vektoren (Context-Vectors) bestehen jeweils aus einem Pfad im abstrakten Syntaxbaum, mit dem jeweiligen Starttoken und Endtoken des Pfades. Danach folgt ein Hidden Layer, mit \tanh als Aktivierungsfunktion. Der endgültige Vektor wird als lineare Kombination aus den Output-Vektoren und den Attention-Weights berechnet. Sei $h_1, \dots, h_n \in \mathbb{R}^d$ die Output-Vektoren von dem Hidden Layer und $\alpha \in \mathbb{R}^n$ der Attention-Weights Vektor.

$$\text{code vector } v = \sum_{i=1}^n \alpha_i \cdot h_i$$

Mit dem Code-Vector kann dann das gewünschte Label vorhergesagt werden. Das Modell kann demnach darauf trainiert werden, bei gegebenem Code-Vector bzw. Quellcodeauszug ein bestimmtes Label in natürlicher Sprache vorherzusagen. Nachdem das Training abgeschlossen ist, kann es ein Label für einen Quellcode vorhersagen, welches nicht im Trainingsatz enthalten ist. Die Trainingsart ist demnach überwachtes Lernen, was eine Aufbereitung der Daten benötigt. Das

Modell kann lediglich die Labels vorhersagen, die es vorher im Training gesehen hat.

2.5 T-Distributed Stochastic Neighbor Embedding

T-Distributed Stochastic Neighbor Embedding (**t-SNE**) ist ein Algorithmus, welcher zum Visualisieren von hochdimensionalen Daten eingesetzt wird [15]. Um das zu ermöglichen, reduziert *t-SNE* die Dimension von $n \in \mathbb{N}$ zu einer niedrigeren Dimension wie zwei oder drei, in der der Mensch die Datenpunkte leicht interpretieren kann. Dabei versucht der Algorithmus, die Nachbarschaftsverhältnisse der Datenpunkte möglichst zu erhalten.

Im Folgenden wird der Algorithmus skizziert und danach wird aufgezeigt, was bei der effektiven Verwendung von *t-SNE* zu beachten ist. Die hochdimensionalen Datenpunkte werden mit **H** und die niedrigdimensionalen Datenpunkte mit **N** bezeichnet. Der erste Schritt des Algorithmus ist es, jedem Datenpunktpaar im Datensatz **H** einen Ähnlichkeitsscore zuzuweisen. Dieser wird berechnet, indem man zuerst die euklidische Distanz von jedem Datenpaar berechnet und dann das Ergebnis in eine Wahrscheinlichkeitsverteilung eingibt. Dies führt zu einer Normalisierung des Wertes. Das Ergebnis ist dann eine Tabelle mit einem Ähnlichkeitsscore für jedes Datenpaar in **H**.

Als Nächstes werden die Datenpunkte zufällig in der niedrigen Dimension **N** angeordnet. Die nachfolgenden zwei Schritte werden $T \in \mathbb{N}$ mal wiederholt, wobei T ein Parameter ist, der wählbar ist.

1. Berechne Ähnlichkeitsscore von **N**, diesmal wird aber die studentische t-Verteilung als Wahrscheinlichkeitsverteilung genommen.
2. Verschiebe die Datenpunkte von **N** um einen kleinen Wert in die Richtung, die den Unterschied der Ähnlichkeitsscores von **H** und **N** minimiert.

Nach T Wiederholung ist der Ähnlichkeitsscore von **N** und **H** nahe bei einander, d.h. die Nachbarschaftsverhältnisse von **N** und **H** sind nun ähnlich.

Wattenberg et al. haben untersucht, wie man *t-SNE* sinnvoll anwendet und welche Schlüsse man aus der Visualisierung ziehen kann [18]. Sie fanden heraus, dass die Wahl der Parameter für das Ergebnis eine wichtige Rolle spielen. Die wichtigsten Parameter sind die Iterationen $T \in \mathbb{N}$ und die Perplexity $P \in \mathbb{N}$.

Eine geeignete Iteration T kann relative einfach durch ausprobieren herausgefunden werden: Falls sich die Datenwolke bei Erhöhung von T nicht mehr wirklich verändert, ist die Anzahl der Iteration T gefunden.

Die Perplexity kann intuitiv als Schätzung für die Anzahl an nahen Nachbarn, die jeder Datenpunkt hat, gesehen werden. Die Suche nach einer geeigneten Perplexity ist schwieriger, da wir die Anzahl der Nachbarn in den hochdimensionalen Daten häufig nicht kennen. Van der Maaten et al., welche *t-SNE* entwickelt haben, empfehlen eine Perplexity $P \in \{5, 6, \dots, 50\}$ [15]. Außerhalb dieses Bereichs kann es zu unerwünschten Ereignissen kommen. Bei $P = 2$ haben Wattenberg et al. herausgefunden, dass *t-SNE* bei einer zufällig generierten Datenwolke fälschlicherweise kleine Gruppierungen (engl. cluster) bildet. Falls P größer ist als die Anzahl der Datenpunkte, ist das Ergebnis überhaupt nicht interpretierbar. Es ist daher ratsam, mehrere Werte für P zu verwenden, um sicherzustellen, dass *t-SNE* keine falschen Nachbarschaftsbeziehungen darstellt.

Wattenberg et al. stellten außerdem fest, dass sowohl die Information des Durchmessers eines Clusters als auch die Abstände zwischen einem Cluster und einem anderen durch *t-SNE* vollständig verloren gehen. Nach Betrachtung der *t-SNE* Ausgabe kann daher keine Aussage über den Durchmesser eines Clusters, die Position des Clusters und die Lagebeziehungen zwischen Clustern getroffen werden.

Der *t-SNE* Algorithmus ist ein wichtiges Tool, um qualitative Aussagen über Daten zu treffen. Es ist jedoch wichtig, mehrere Parameter auszuprobieren. Es kann nur eine Aussage über die Existenz von Clustern gemacht werden, nicht über ihre geometrischen Gegebenheiten. Wenn diese Bedingungen beachtet werden, kann *t-SNE* ein mächtiges Visualisierungs-Tool sein, um eine Intuition für die Anordnung der Datenpunkte zu erlangen.




Abbildung 3.1: Die Datenpipeline dargestellt, dabei sind Vierecke mit abgerundeten Ecken Tools, die Daten in eine andere Darstellung umwandeln.

3 Methodik

3.1 Datensatz

Im maschinellen Lernen hat der Datensatz bzw. die Trainingsdaten den größten Einfluss auf die Güte des Modells. Wir haben uns für die Open Source-Standard-C-Bibliothek von GNU entschieden. Die Sprache C wurde gewählt, da sie die zweitpopulärste Sprache nach C++ ist, die zu Maschinencode kompilierbar ist.³ Die GNU-Bibliothek wurde aufgrund der hohen Qualität des Quellcodes ausgewählt, da das Projekt seit 1987 existiert und die Community jederzeit auf Fehler im Quellcode hinweisen kann. Zum anderen wird die Bibliothek weitgehend in vielen Applikationen eingesetzt. Der wichtigste Aspekt ist, dass man mit diesem Datensatz die Ergebnisse des trainierten Modells vergleichen kann, da die C-Bibliothek im POSIX-Standard festgelegt ist und mehrfach implementiert wurde. Dadurch erhält man mehrere hochqualitative Quellcodeprojekte, die die gleiche Semantik aufweisen. Die unterschiedlichen Implementierungen werden zu unterschiedlichem Assemblercode kompiliert. Deswegen kann mit unterschiedlichen Standard-C-Bibliotheken, die den POSIX-Standard implementieren, getestet werden, ob das finale Modell beide Implementierungen als sehr ähnlich klassifiziert.

3.2 Datenpipeline

Der große praktische Teil der Arbeit bestand darin, eine große Menge an Daten in unterschiedliche Darstellungen umzuwandeln. Jeder Zwischenschritt wurde gespeichert, um nicht jede Darstellung erneut generieren zu müssen. Im Folgenden wird die generelle Architektur, wie Daten verarbeitet werden (engl. pipeline), vorgestellt, um einen Überblick über den praktischen Teil dieser Arbeit zu geben.

Die Rohdaten entsprechen dem unverarbeiteten C-Quellcode aus der GNU-Standard-C-Bibliothek. Wir benötigen nicht alle Teile des Quellcodes, sondern nur bestimmte. Wir betrachten ausschließlich

³<https://www.jetbrains.com/lp/devecosystem-2024/>

nur Funktionen, d.h. wir wollen bspw. alle Datenstrukturen, die in dem Quellcode definiert werden, aus dem Quellcode entfernen. Die Zerlegung und Umwandlung des Inputs in sinnvolle Teile wird Parsing genannt.

In dieser Arbeit wurde **Tree-sitter**⁴ als Parser verwendet, welcher alle populären Programmiersprachen in Syntaxbäume umwandeln kann. Ursprünglich wurde *Tree-sitter* für den Texteditor Atom entwickelt und wird heute noch in vielen Texteditoren bspw. für die Hervorhebung von Syntax verwendet. Generell kann *Tree-sitter* jedoch für alle Anwendungen benutzt werden, die Informationen aus Quellcode verarbeiten wollen. Aus dem von *Tree-sitter* generierten Syntaxbaum kann dann jegliche gewünschte Information entnommen werden.

Die Quellinformationen werden immer zunächst gespeichert, damit die Verarbeitung beim nächsten Mal an diesem Punkt beginnen kann. Die Quellinformationen beziehen sich immer auf eine Funktion, deswegen bestehen die Daten aus einem Tupel, der aus je einer Funktion und den gewünschten Quellinformationen besteht.

Nachdem die Quellcode-Informationen extrahiert wurden, gibt es eine Abzweigung in der Datenpipeline, entweder werden die Quellinformationen von Code Llama nochmal in natürlicher Sprache beschrieben und dann in den *SentenceTransformer* eingegeben oder die Quellinformation wird direkt in den *SentenceTransformer* eingegeben. Schließlich erhält man wieder eine Datenmenge, die aus Tupeln besteht. Ein Tupel besteht aus dem Funktionsnamen und dem zugewiesenen semantischen Embedding. Bei dieser Architektur kann mühelos jedes Tool ausgewechselt werden, solange die Ausgabeformate eingehalten werden.

3.3 Stabilität von SentenceTransformer

Im vorherigen Abschnitt haben wir festgestellt, dass der endgültige Schritt für alle Daten der *SentenceTransformer* ist, deshalb bildet er das Herzstück der Datenpipeline. In dieser Arbeit sollen verschiedene semantische Beschreibungen des Quellcodes in natürlicher Sprache verglichen werden. Es ist wichtig, dass alle anderen Elemente in der Datenpipeline konstante Ergebnisse liefern und nicht schwanken. Aus diesem Grund wird im Folgenden untersucht, wie sich der *SentenceTransformer* bei selber Eingaben verhält. Im Optimalfall sollte der *SentenceTransformer* bei selbem Input dasselbe Ergebnis liefern.

Um dies zu überprüfen, wurden $n = 100$ Code-Llama-Quellcode-Erklärungen zufällig ausgewählt und anschließend in den *SentenceTransformer* $m = 100$ Mal eingegeben. Dabei beträgt der höchste Abstand von zwei Vektoren, die aus der gleichen Erklärung resultiert sind $d = 6.661338 \cdot 10^{-16}$. Der Abstand ist ausreichend klein, um ihn in der Evaluation zu vernachlässigen. Der *SentenceTransformer* ist daher für die Anwendung in dieser Arbeit ausreichend stabil.

⁴<https://tree-sitter.github.io/tree-sitter/>

```

// Calculates the factorial of an int.
unsigned long long factorial(int n) {
    // Base case: Factorial of 0 is 1
    if (n == 0) {
        return 1;
    }
    // Recursive case: n! = n * (n-1)!
    return n * factorial(n - 1);
}

```

{
"factorial": "Calculates the factorial of an int."
}

Abbildung 3.2: Links ein Quellcode-Beispiel und rechts der extrahierte Kommentar

3.4 Funktionskommentare

Bevor ein Programm kompiliert wurde, gibt es eine Menge an Informationen, die die Semantik der Funktion in natürlicher Sprache beschreiben. Eine offensichtliche Quellcodeinformation, die im Optimalfall die Semantik der Funktion in natürlicher Sprache beschreibt, ist der Kommentar. Ein gelungener Kommentar zu einer Funktion beschreibt die Kernfunktion der Prozedur, d.h. den Input, den Output und die Umwandlung. Dieser Kommentar kann dann in den SentenceTransformer eingegeben werden und so in einen semantischen Vektorraum abgebildet werden.

Das Parsen der Kommentare wurden mit *Tree-sitter* realisiert, wie im Abschnitt zur Datenpipeline erwähnt. Dabei gab es eine große Designentscheidung zu treffen, welche Kommentare in einer Funktion berücksichtigt werden sollen. Im Rahmen dieser Arbeit werden ausschließlich Kommentare verwendet, die direkt über der Funktion in stehen. Diese Designentscheidungen wurde unter der Hypothese getroffen, dass die einzeiligen Kommentare innerhalb der Funktion meistens keinen großen semantischen Wert haben, sondern auf Gefahren oder Designentscheidungen hinweisen. Hierbei sollte man aufpassen, dass der Prozess des Parsen nicht zu speziell an die vorliegenden Datensatz angepasst wird, sonst verliert er seine Allgemeingültigkeit.

3.5 Code2Vec

Das Besondere an *Code2Vec* ist, dass der Quellcode in einem abstrakten Syntaxbaum kodiert wird. Dies ermöglicht die Verwendung aller Quellcodeinformationen, die im Quellcode enthalten sind. Anschließend wird das Modell darauf trainiert, eine Eigenschaft in natürlicher Sprache über den Quellcode vorherzusagen.

Bei dieser Herangehensweise, semantische Vektoren zu erzeugen, wird also kein *SentenceTransformer* verwendet, sondern die Vektoren werden durch Training des *Code2Vec* Modells als Nebenprodukt erzeugt. Wie in dem [3] wird das Modell auch hier darauf trainiert, Funktionsnamen vorherzusagen. Die Implementierung des *Code2Vec* Modells nutzte Java als Datensatz, weshalb einige Anpassungen notwendig waren, um das Modell auf C-Quellcode zu trainieren.

Das *Code2Vec*-Modell basiert auf überwachtem Lernen, deswegen wird der Datensatz vor dem Training zunächst aus dem rohen Quellcode aufbereitet.

3.5.1 Adaption auf C

Um das *Cod2Vec*-Modell zu trainieren, ist es notwendig, aus dem rohen Quellcode einer Funktion jeweils einen abstrakten Syntaxbaum und den Funktionsnamen zu extrahieren. Alon et al. stellen




Abbildung 3.3: Extrahierung eines Kontexts aus einem C-Quellcode

ein Tool für Java zur Verfügung, welches das Extrahieren von abstrakten Syntaxbäumen und Funktionsnamen aus Java-Quellcode ermöglicht, deswegen war hier ein externes Tool notwendig. Mit dem *ASTminer* von Kovalenko et al. können abstrakte Syntaxbäume und Funktionsnamen extrahiert werden [20]. Das Tool wurde vom JetBrains-Research-Team entwickelt, um Quellcode in abstrakte Syntaxbäume (AST) zu kodieren, die als Input-Format für maschinelles Lernen dienen. Für die Implementierung des *Code2Vec*-Modells ist es erforderlich, dass der Datensatz ein bestimmtes Format aufweist. Ein Trainingsbeispiel besteht jeweils aus einem Funktionsnamen, dem Label und einer Liste von Kontexten, welche den AST repräsentieren. Ein Kontext besteht aus einem Starttoken, einem Endtoken und einer Pfadbeschreibung vom Starttoken bis zum Endtoken. Dieses *Code2Vec*-Format kann durch eine zusätzliche Option in der Konfiguration des *ASTminers* generiert werden. Obwohl diese Option mit „code2vec“ betitelt ist, ist der Output des *ASTminers* nicht direkt von *Code2Vec* verwendbar. Das Tool weist nämlich jedem Token eine einzigartige Zahl zu und verwendet dann im Datensatz nur noch die Zahl. Dieses Format reduziert zwar den Speicheraufwand, aber es wird von *Code2Vec* nicht als valide Eingabe akzeptiert. Demnach wurden schließlich noch die Nummern wieder zu den passenden Token umgewandelt. In Abbildung 3.3 ist der Prozess abgebildet von wie der anfänglich Quellcode zu dem *code2vec*-Input-Format umgewandelt wurde. Da es unterschiedliche Konventionen für Funktionsnamen gibt, wie z.B. Camel-Case und Snake-Case, normalisiert der *ASTminer* die Funktionsnamen. Dadurch sind die Trainingsdaten unabhängig von den jeweiligen Quellcodekonventionen.

Beispiel 3.1

Snake-Case: funktions_name → **funktions|name**
Camel-Case: funktionsName → **funktions|name**

Das *Code2Vec*-Modell kann nach dem Training für jede Funktion einen hochdimensionalen Vektor ausgeben, der die Semantik der Funktion beschreiben soll. Um mit *Code2Vec* diesen Vektor generieren zu können, ist es notwendig den abstrakten Syntaxbaum als Input hinein zugeben. Die abstrakten Syntaxbäume können nur durch ihren normalisierten Namen identifiziert werden, da sie als Tupel in dieser Form im Datensatz vorliegen. Die normalisierten Namen können nicht mehr eindeutig dem initialen Funktionsnamen zugeordnet werden, da durch die Normalisierung Informationen verloren gehen. Zur Vergleichbarkeit von *Cod2Vec* mit anderen Ansätzen wie z.b. Funktionskommentaren ist es aber wichtig, die normalisierten Namen wieder zu den ursprünglichen Namen zurückzuführen. Aufgrund dessen wurden im Quellcode von *ASTminer* Änderungen vorgenommen, sodass zu jeder Position eines Trainingsbeispiels im Datensatz der ursprüngliche Funktionsname zugeordnet werden kann.

```

// Calculates the factorial of an int.
unsigned long long factorial(int n) {
    // Base case: Factorial of 0 is 1
    if (n == 0) {
        return 1;
    }
    // Recursive case: n! = n * (n-1)!
    return n * factorial(n - 1);
}

```

{ "factorial": "factorial" }

Abbildung 3.4: Links ein Quellcode-Beispiel und rechts der extrahierte Funktionsname

3.5.2 Training

Das Ziel beim Training war es, dieselbe Qualität wie Alon et al. zu erzielen. Das heißt, dieselben Ergebnisse für Java auch für C-Quellcode zu replizieren. Bei der Erstellung eines Datensatzes, der aus dem Modell resultiert, können bestimmte Gütekriterien beim Trainieren von Modellen vernachlässigt werden. Eine Problemstellung beim Trainieren von Modellen ist es, inwiefern das Modell generalisiert, also wie leistungsfähig das Modell auf neuen Daten im Gegensatz zu den Trainingsdaten ist. Es ist nicht notwendig diese Problemstellung zu berücksichtigen, da das Ergebnis kein fähiges Modell ist, sondern semantische Vektoren. Auch der kleine Datensatz, mit $n = 5155$ Datenpunkten, ist zwar für die Güte des Modells problematisch, jedoch nicht für die resultierenden semantischen Vektoren. Selbst wenn das Modell nur die passenden Funktionsnamen auswendig lernt, entstehen dabei Vektoren, die gewisse Informationen des Namens widerspiegeln.

Nachdem das Trainingsszenario genau dasselbe wie bei Alon et al. ist, wurden alle Trainingsparameter gleich gelassen. Die Ergebnisse nach der 84 Epoche sind: **Precision:** 65.6, F_1 : 65.1, **Recall:** 64.7. Diese Werte sind etwas über den Werten von den *Code2Vec* Autoren, sie kamen beim Full Test-Set auf: **Precision:** 63.1, F_1 : 58.4, **Recall:** 54.4. Dabei ist hervorzuheben, dass unser Test- und Trainings-Datensatz derselbe ist und der Test-Datensatz von *Code2Vec* verschieden ist von dem Trainings-Datensatz. Die Vorgehensweise ist normalerweise grob fahrlässig, da wir nicht die Generalisierung des Modells messen. In diesem speziellen Anwendungszweck ist jedoch die Güte des Modells nicht von Bedeutung, sondern nur die Güte der erzeugten Vektoren. Damit haben wir ähnliche Ergebnisse wie im Modell von Alon et al. und können diese mit den anderen vorgestellten Ansätzen vergleichen [3].

3.6 Funktionsnamen

Eine andere Quellinformation, die in jedem Quellcode enthalten ist, sind die Funktionsnamen. Funktionsnamen sollen in wenigen Wörtern den Kerninhalt der Funktion widerspiegeln. Dadurch eignen sich Funktionsnamen, um die Semantik einer Funktion zu beschreiben. Die Extrahierung von Funktionsnamen ist keine schwierige Aufgabe. Hierfür wäre *Tree-sitter* nicht unbedingt nötig gewesen, aber falls ein Datensatz für eine andere Sprache wie Rust erstellt werden sollte, müsste der Parser immer wieder angepasst werden. Deswegen wurde hier für die einfache Erweiterung des Programms, *Tree-sitter* verwendet, da *Tree-sitter* Parser für eine Vielzahl von Sprachen anbietet.

```

llama_prompt = """
    Can you briefly summarize in one or two
    sentence what the following function does?
    And can you give just the summary?
    """

```

Abbildung 3.5: Die verwendete Prompt für das Code-Llama-Modell

3.7 Code-Llama-Erklärungen

Large Language-Models werden immer besser, Quellcode selbst zuschreiben, zu verstehen und zusammenzufassen. Eine Zusammenfassung des Quellcodes in natürlicher Sprache spiegelt die Semantik des Quellcodes wider. So ist auch *Code Llama* fähig, Quellcode zu erklären und somit einen Text zu generieren, der die Semantik der Funktion enthält. Dieser Ansatz verwendet wie *Code2Vec* jede Quellcodeinformation, da der gesamte Quellcode als Eingabe genutzt wird.

Code Llama generiert Quellcodeerklärungen, indem Code Llama eine präzise Fragestellung und den gesamten Quellcode einer Funktion erhält. Die Fragestellung (engl. prompt) ist in Abbildung 3.5 dargestellt.

Damit der Code-Llama-Output deterministisch ist, ist es erforderlich, den Temperaturparameter auf null zu setzen. Der Parameter ist Teil einer Zufallskomponente bei der Auswahl des nächsten Tokens, ist dieser auf null, wird der Token mit dem höchsten Score gewählt, dieser bleibt bei gleicher Eingabe immer derselbe. Leider ist der Determinismus trotzdem nicht garantiert, wie die Studie von Astekin et al. heraus fand [21]. Laut Astekin et al. könnte ein Grund dafür sein, dass bei den vielen Fließkommaoperationen, die für die Berechnung eines Code-Llama-Outputs erforderlich sind, Rundungsfehler entstehen. Diese Erkenntnisse stammen aber aus einem anderen Anwendungszweck, nämlich für Log-Parsing, geben aber ein Indiz auf eine mögliche Instabilität. Die Stabilität mit Temperatur Null sollte daher für den Anwendungszweck dieser Arbeit getestet werden. Um das zu überprüfen, wurden von $n = ?$ Funktionen der Quellcode mit Fragestellung $m = ?$ Mal in Code Llama eingegeben, bei den resultierenden Vektoren beträgt der höchste Abstand von zwei Vektoren, die aus dem gleichen Quellcode resultiert sind, $d = ?$. Dieser Abstand ist ausreichend gering, um ihn in der Evaluation zu vernachlässigen. Code Llama ist also für die Anwendung in dieser Arbeit ausreichend stabil.

"fmaximum_numl"	"execl"
1. fminimum_magl	1. j1l
2. fminimuml	2. exp10l
3. fminimum_mag_numl	3. exp2l
4. fminimum_numl	4. expm1l
<input type="radio"/> Yes	<input type="radio"/> Yes
<input type="radio"/> No	<input type="radio"/> No

Abbildung 3.6: Auf der linken Seite eine Frage aus dem Fragebogen die positiv beantwortet wurde und rechts eine Frage die negativ beantwortet wurde.

4 Ergebnisse

Im letzten Kapitel wurden vier verschiedene Strategien vorgestellt, eine C-Quellcode-Funktion in einen semantischen Vektorraum abzubilden. Zum einen die Verwendung von Funktionsnamen und Funktionskommentaren die direkt aus dem C-Quellcode entnommen wurden, um diese mittels *SentenceTransformer* in Vektoren umzuwandeln. Zum anderen aus dem gesamten C-Quellcode einer Funktion eine Erklärung von Code Llama zu generieren, um diese Erklärung wieder mittels *SentenceTransformer* in Embeddings umzuwandeln. Schließlich das *Code2Vec*-Modell darauf zu trainieren, bei gegebenem C-Quellcode einen Funktionsnamen vorherzusagen, dann daraus die Vektoren zu extrahieren, die für die Inferenz des Namens bei gegebenem C-Quellcode verwendet werden.

Nun soll in diesem Kapitel untersucht werden, welche der vier Strategien die besten Embeddings erzeugt und wie ähnlich die anderen semantischen Vektorräume zu dem Vektorraum der besten Strategie sind.

Um diese Frage zu beantworten, welche der vorgestellten Strategien die besten semantischen Embeddings liefern, wurde eine Expertenbefragung durchgeführt. Anschließend werden die erzeugten Vektorräume quantitativ mittels einer Formel, die die Nachbarschaftsverhältnisse vergleicht, ausgewertet. Zum Schluss wird qualitativ die durch *t-SNE* erzeugten zwei dimensional Streudiagramme verglichen.

4.1 Befragung von Experten

Um die Befragung von Experten durchzuführen, wurde zunächst ein Fragebogen erstellt, dafür wurde die von der Ludwig-Maximilians-Universität bereitgestellte Internetseite verwendet⁵. Der Fragebogen besteht aus $n = 564$ Fragen, wobei jede Frage aus einer Funktion und den vier nächsten Nachbarn der Funktion im Embedding-Raum besteht. Davon sind jeweils $k = 141$ Fragen, um einen Embedding-Raum zu untersuchen. Also wurden, um einen Embedding-Raum zu untersuchen, k zufällige Funktionen und ihre vier nächsten Nachbarn verwendet. Die vier Embedding-Räume stammen aus den vier Strategien (*Code2Vec*, Funktionsnamen, Funktionskommentare und Code-Llama-Erklärungen) Embeddings zu erzeugen. Die Fragestellung ist nun, ob die vier nächsten Nachbarn der gegebenen Funktion semantisch ähnlich sind oder nicht.

⁵<https://survey.ifkw.lmu.de/>

Ergebnisse der Expertenbefragung				
Strategie	Funktionskommentare	Funktionsnamen	<i>Code2Vec</i>	Code-Llama-Erklärungen
Score	0	0	0	0

Tabelle 1: Ergebnisse der Expertenbefragung

Diese Fragen wurden dann Experten aus dem Bereich Reverse Engineering vorgelegt. In der Abbildung 3.6 ist ein Auszug aus dem Fragebogen dargestellt.

Die Auswertung des Fragebogens geschah wie folgt: Jede Frage, die positiv beantwortet wurde, gibt einen Punkt, um daraus nun einen Score zu berechnen werden die Punkte summiert und dann anschließend durch die maximal zu erreichenden Punkte k geteilt. Das Resultat ist ein normalisierter Score, der bei $\text{score} = 1$ impliziert, dass alle Fragen positiv beantwortet wurden und bei $\text{score} = 0$ impliziert, dass keine Frage positiv beantwortet wurde. Diese Auswertung liefert folgendes Resultat, welches in Tabelle 1 abgebildet ist.

Die Strategie mit dem höchsten Score ist demnach die, die Code-Llama-Erklärungen verwendet hat. Da nun die beste Strategie identifiziert ist, werden im Folgenden die anderen Strategien mit dieser quantitativ verglichen.

4.2 Quantitative Evaluierung

Im Folgenden wird eine Formel vorgestellt, die zwei Datenmengen auf Ähnlichkeit untersuchen soll. Dabei ist Ähnlichkeit hier, ähnliche Nachbarschaftsbeziehungen zu besitzen. Im Folgenden wird eine Datenmenge als Matrix $\mathbf{D} \in \mathbb{R}^{N \times l}$ beschrieben. Dabei ist $l \in \mathbb{N}$ die Dimension eines Datenpunkts und $N \in \mathbb{N}$ die Anzahl der Datenpunkte. Folglich besitzt jeder Datenpunkt $x \in \mathbb{R}^l$ einen eindeutigen Index und zwar die j -te Zeile, für die gilt: $x = \mathbf{D}_j$, wobei \mathbf{D}_j der j -te Zeilenvektor von \mathbf{D} ist.

Zunächst wird eine Methode benötigt, um Nachbarn von einem gegebenen Punkt zu erlangen, dafür wird hier der *K-Nearest-Neighbor-Algorithmus* verwendet. Dieser gibt bei gegebenem Punkt die k nächsten Nachbarn zurück. Also eine Funktion mit der Signatur: $NN_k : \mathbb{R}^{N \times l} \times \mathbb{R}^l \rightarrow \mathbb{N}^k$. Die gesamte Datenmenge und ein Datenpunkt wird eingegeben und der Output ist ein Vektor aus Indizes, wobei jeder Index ein Nachbar bzw. ein Datenpunkt ist. Diese sind aufsteigend sortiert, nach dem euklidischen Abstand von dem eingegebenen Punkt. Dadurch erhält man ein Nachbarschaftsverhältnis von einem Punkt und seinen k Nachbarn, in der Form eines Vektors $v \in \mathbb{N}^k$. Als Nächstes wird eine Methode benötigt, zwei Nachbarschaftsverhältnisse in der Form von zwei Vektoren $u, v \in \mathbb{N}^k$ zu vergleichen. Hierfür werden folgende Funktionen mit Signaturen $\text{compare}_k : \mathbb{N}^k \times \mathbb{N}^k \rightarrow [0, 1]$ und $\text{score}_k : \mathbb{N} \times \mathbb{N} \times \mathbb{N}^k \rightarrow \{0, \frac{1}{2}, 1\}$ verwendet:

$$\text{compare}(u, v)_k = \frac{1}{G_k} \sum_{i=1}^k \frac{\text{score}_k(u_i, i, v)}{\log_2(i+1)}$$

mit

$$\text{score}_k(l, i, v) = \begin{cases} 1 & , \exists j \in \mathbb{N} : l = v_j \wedge i = j \\ \frac{1}{2} & , \exists j \in \mathbb{N} : l = v_j \wedge i \neq j \\ 0 & , \text{otherwise} \end{cases} \quad \text{und} \quad G_k := \sum_{i=1}^k \frac{1}{\log_2(i+1)}.$$

Dabei ist die Funktion compare_k stark durch den Normalised Discounted Cumulative Gain von Järvelin und Kekäläinen inspiriert [22].

Die Datenpunkte innerhalb einer Gruppierung haben zueinander einen geringen Abstand. Aus diesem Grund ist der Score von einem Nachbarn mit großem Abstand zum Bezugspunkt weniger bedeutsam als ein Nachbar mit geringem Abstand. Da die Nachbarn aufsteigend nach Abstand zu einem gegebenen Bezugspunkt sortiert sind, wird der Score durch einen Wert geteilt, mit wachsenden Index größer. Dadurch haben Nachbarn, die weiter entfernt sind, weniger Einfluss auf die Summe. Schließlich wird noch normalisiert, indem die höchste zu erreichende Summe an Scores durch das Ergebnis geteilt wird.

Die Funktion score_k berechnet, wie ähnlich zwei Nachbarschaftsverhältnisse $u, v \in \mathbb{N}^k$ bei gegebenen Nachbarn $l = u_i$ sind. Den höchsten Wert $\text{score}_k(l, i, v) = 1$ bekommt ein Nachbar $l = u_i$ der im Nachbarschaftsverhältnis von v enthalten ist und auf derselben Position im Abstands-Ranking von v ist. Der Wert $\text{score}_k(l, i, v) = \frac{1}{2}$ bekommt ein Nachbar $l = u_i$ der im Nachbarschaftsverhältnis v enthalten ist, aber nicht auf derselben Position im Abstands-Ranking von v ist. Schließlich erhält ein Nachbar $l = u_i$ den Score $\text{score}_k(l, i, v) = 0$, falls er gar nicht im Nachbarschaftsverhältnis von v enthalten ist.

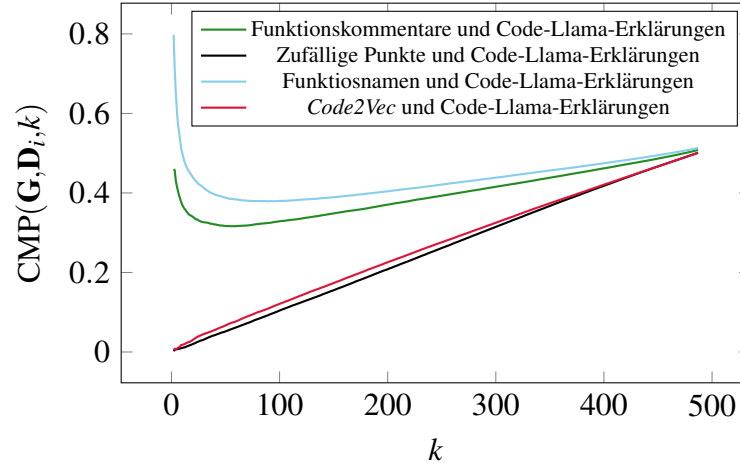


Abbildung 4.1: Der Graph bildet ab, wie ähnlich verschiedene Embedding-Prozesse zu den Code-Llama-Erklärungen sind, für $k = 2, 3, \dots, 487$, wobei k die Anzahl der betrachteten Nachbarn ist.

Um nun zwei Datenmengen zu vergleichen, müssen alle möglichen Nachbarschaftsverhältnisse betrachtet werden. Das motiviert folgende Funktion mit Signatur: $CMP : \mathbb{R}^{N \times l} \times \mathbb{R}^{N \times l} \times \mathbb{N} \rightarrow [0, 1]$. Dabei wird angenommen, dass $A, B \in \mathbb{R}^{N \times l}$ Datenmengen sind, die aus unterschiedlichen Embedding-Prozessen entstanden sind, aber aus der gleichen Grundmenge sind. Bei einer Grundmenge $H \in F^N$, wobei F eine beliebige Menge ist und $E_1, E_2 : F \rightarrow \mathbb{R}^l$ Embedding-Prozesse sind, gilt dann:

$$A_j = E_1(H_j) \quad \text{und} \quad B_j = E_2(H_j).$$

Dadurch können Nachbarschaftsverhältnisse der Datenmengen A, B verglichen werden, indem die Nachbarschaftsverhältnisse desselben Grundmenge in unterschiedlichen Embedding-Räumen verglichen werden:

$$CMP(A, B, k) = \frac{1}{N} \sum_{i=1}^N \text{compare}_k(NN_k(A_i, A), NN_k(B_i, B))$$

Um die Ergebnisse der compare_k Funktion zu aggregieren, wird hier das arithmetische Mittel verwendet. Bei den verwendeten Embedding-Prozessen in dieser Arbeit sind Elemente der Grundmenge verloren gegangen. Die Grundmenge besteht hier aus den Funktionen aus der GNU-C-Standard-Bibliothek. Die Anzahl der Vektoren in den resultierenden Datenmengen sind deswegen verschieden:

$$\begin{aligned} \text{Funktionsnamen} &\leftrightarrow \mathbf{D}_1 = \mathbb{R}^{1507 \times 384}, \text{Funktionskommentare} \leftrightarrow \mathbf{D}_2 = \mathbb{R}^{487 \times 384}, \\ \text{Zufällige-Datenmenge} &\leftrightarrow \mathbf{D}_3 = \mathbb{R}^{1507 \times 384}, \text{Code2Vec} \leftrightarrow \mathbf{D}_4 = \mathbb{R}^{896 \times 384} \quad \text{und} \\ \text{Code-Llama-Erklärungen} &\leftrightarrow \mathbf{G} = \mathbb{R}^{1507 \times 384}. \end{aligned}$$




Abbildung 4.2: Die t -SNE Vektoren der unterschiedlichen Embedding-Prozesse mit Perplexity-Parameter $P = 30$.

Um die Datenmengen vergleichen zu können, wurde das Minimum der Anzahl der Vektoren der verschiedenen Datenmengen genommen: $N := 487 = \min(1507, 487, 1507, 896, 1507)$. Da die Wahl von k nicht offensichtlich ist, werden die Ergebnisse für alle $k = 2, 3, \dots, N$ berechnet und in einem Graphen abgebildet. Der daraus resultierende Graph ist in Abbildung 4.1 dargestellt. In dem Graphen ist folgende Ordnung zu erkennen:

$$\forall k = 2, 3, \dots, 487 : CMP(\mathbf{G}, \mathbf{D}_3, k) \leq CMP(\mathbf{G}, \mathbf{D}_4, k) \leq CMP(\mathbf{G}, \mathbf{D}_2, k) \leq CMP(\mathbf{G}, \mathbf{D}_1, k)$$

Das heißt, laut vorgestellter Formel ist der Embedding-Prozess Funktionsnamen am ähnlichsten zu den Code-Llama-Erklärungen, danach Funktionskommentare, *Code2Vec*-Vektoren und schließlich zufällige Vektoren.

4.3 Qualitative Evaluierung

Die qualitative Evaluierung wird in dieser Arbeit mittels t -SNE durchgeführt. Dabei wird t -SNE verwendet, um die hochdimensionalen Vektoren $x \in \mathbb{R}^{384}$ in einen zweidimensionalen Vektorraum zu projizieren. Bei der Verwendung und Interpretation von t -SNE gibt es einiges zu beachten.

Zum einen sollten bei der Verwendung mehrere Werte für den Perplexity-Parameter $P \in \{2, 3, \dots, 50\}$ ausprobiert werden. Zum anderen kann aus den zweidimensionalen Datenmengen nur eine Aussage über die Existenz von Clustern abgeleitet werden und nicht über die Position und Größe einer Gruppierung. Sogar die Existenz eines Clusters in der zweidimensionalen Datenmenge ist zwar ein starkes Indiz, dass ein Cluster in den hochdimensionalen Daten existiert, aber kein Beweis.

Es wurden die Werte $P \in \{20, 30, 40\}$, als Perplexity-Parameter verwendet, um verschiedene Werte auszuprobieren, die jeweils nicht am Rand der empfohlenen Menge $\{2, 3, \dots, 50\}$ liegen. Um aussagekräftige Graphen zu erhalten, wurden 1182 Funktionen aus der GNU-Standard-C-Bibliothek in 10 Kategorien unterteilt. Die Streudiagramme mit unterschiedlichen Perplexity-Parameter sind jeweils im Anhang zu finden.

"fmaximum_numl"	"execl"
1. fminimum_magl	1. j1l
2. fminimuml	2. exp10l
3. fminimum_mag_numl	3. exp2l
4. fminimum_numl	4. expm1l
<input checked="" type="radio"/> Yes	<input type="radio"/> Yes
<input type="radio"/> No	<input type="radio"/> No

Abbildung 4.3: Auf der linken Seite eine Frage aus dem Fragebogen die positiv beantwortet wurde und rechts eine Frage die negativ beantwortet wurde.

Da nun mehrere Werte für den Perplexity-Parameter ausprobiert wurden, ohne große Unterschiede in den Gruppierungen zu erkennen, werden im Folgenden die vier verschiedenen Strategien, Embeddings zu erzeugen, mit $P = 30$ abgebildet, um sie qualitativ zu vergleichen. Die vier Streudiagramme sind in Abbildung 4.2 dargestellt.

Die vier durch *t-SNE* generierten Datenmengen liefern ein Indiz, dass die Anzahl der Gruppierungen zunehmen, in der Reihenfolge: *Cod2Vec*, Kommentare, Namen und Code-Llama-Erklärungen. Das heißt, auch die qualitative Evaluierung scheint dem Trend zu folgen, dass die Qualität der Embeddings gleichermaßen aufsteigend angeordnet ist.

5 Diskussion

Das zentrale Thema dieser Arbeit, ist die semantische Ähnlichkeit von zwei gegebenen Quellcode Auszügen. Dabei ist es gar nicht so klar was eine gute Definition für semantische Ähnlichkeit ist. Anhand eines Auszugs aus dem Fragebogen der in Abbildung 4.3 dargestellt ist, ist gut zu erkennen, was in diesen Kontext mit semantischer Ähnlichkeit gemeint ist.

In dem positiven Beispiel in der Abbildung 4.3, ist eine Funktion gegeben die das Maximum von zwei Fließkommazahlen berechnet und die vier nächsten Nachbarn sind jeweils Variationen von Funktionen die das Minimum von zwei Fließkommazahlen berechnen. Diese Funktionen sind semantisch ähnlich, da sie fast äquivalente Funktionen aus dem Mathematikmodul sind. Im negativen Beispiel der Abbildung 4.3 kreiert die gegebene Funktionen einen neuen Prozess, dagegen haben aber die nächsten Nachbarn zwar einen sehr ähnlichen Namen, aber es sind wieder Funktionen aus dem Mathematikmodul.

Daher bevorzuge ich die Definition, dass zwei Funktionen semantisch Ähnlich sind, wenn sie in ähnlichen Kontexten verwendet werden. Ein Beispiel hierzu wären verschiedene Sortieralgorithmen, die in den meisten Fällen in den selben Kontexten verwendet werden können und damit semantisch sehr Ähnlich sind. Natürlich ist diese Definition nicht gerade präzise sondern sehr vage.

In dieser Arbeit wurden vier unterschiedliche Strategien vorgestellt, aus C-Quellcode-Funktionen Embeddings zu erzeugen. Die Strategien *Cod2Vec*, Funktionskommentare, Funktionsnamen, Code-Llama-Erklärungen haben alle ihre eigenen Limitationen. Zunächst werden diese Problematiken bzw. Schwächen diskutiert. Danach werden Limitationen und Verallgemeinerungen der *CMP* Funktion vorgestellt. Schließlich wird noch eine Idee für ein neues Modell für zukünftige Forschung beschrieben.

Funktionsnamen. Die Strategie, die Funktionsnamen zu verwenden, um Embeddings zu erzeugen, ist sehr abhängig von dem Quellcode. Selbst bei dem hochqualitativen Quellcode, der GNU-C-Standard-Bibliothek entstehen Probleme, weil die Namen die Semantik der Funktion nicht präzise beschreiben. Das folgende Problem zieht sich systematisch durch die ganze Bibliothek durch. In der GNU-C-Standard-Bibliothek werden konsequent Abkürzungen benutzt, wodurch die Bedeutung zwar für den Mensch aus dem Kontext klar wird, aber wenn die Funktionsnamen die einzige Information ist, sind die Abkürzungen mehrdeutig.

Beispiel 5.1 *Ein Beispiel ist die Funktion `lchmod`. Die Funktion `lchmod` passt die Zugriffsberechtigung einer Datei an, aber folgt dabei nicht symbolischen Links. Dabei werden folgende Abkürzungen verwendet:*

$$l \leftrightarrow \text{link}, \quad ch \leftrightarrow \text{change}, \quad mod \leftrightarrow \text{file mode}.$$

Da diese Abkürzungen nicht offensichtlich sind, haben die durch den *SentenceTransformer* erzeugten Embeddings Nachbarn, welche nicht aus der Kategorie Dateiverwaltung sind. Die Nachbarn der `lchmod` Funktion im Funktionsnamen-Raum sind: `lchmod`, `lcong48`, `fchmodat`, `cosh1` und `cacosh1`. Dabei ist nur `fchmodat` aus der Kategorie Dateiverwaltung, diese liegt wahrscheinlich nur nahe an `lchmod`, da die Namen fast identisch sind. Dagegen sind die nächsten Nachbarn von `lchmod` im Code-Llama-Erklärungen-Raum alle aus der Kategorie Dateiverwaltung: `lchmod`, `fchmodat`, `fchownat`, `euidaccess` und `__file_change_detection_for_stat`.

Funktionskommentare. Die Methodik der Funktionskommentare zu verwenden, um Embeddings zu erzeugen, ist genau wie bei den Funktionsnamen sehr abhängig von dem Quellcode. Auch die Entscheidung, welche Kommentare man einbezieht, könnte Auswirkungen auf die Embeddings haben. In dieser Arbeit wurde nur der Kommentar direkt über der Funktion verwendet. In zukünftiger Forschung könnte untersucht werden, ob die Kommentare innerhalb der Funktion auch verwendet werden könnten, um qualitativ hochwertigere Embeddings zu produzieren.

Auch bei den Funktionskommentaren ist das Problem, dass die Semantik der Funktion sich nicht immer in dem Kommentar widerspiegelt.

Beispiel 5.2 *Die Funktion `rand` und die Funktion `rand_r` sind sehr ähnlich. Erstere generiert eine zufällige Zahl im Intervall $[0, \text{RAND_MAX}]$ und zweitere generiert ebenfalls eine zufällige Zahl im gleichen Intervall, aber erhält noch einen Seed als Parameter. Die beiden Funktionen haben folgende Kommentare:*

`rand` \rightsquigarrow Return a random integer between 0 and RAND_MAX.
`rand_r` \rightsquigarrow This algorithm is mentioned in the ISO C standard, here extended for 32 bits.

Dieses Beispiel zeigt gut, wie unterschiedlich die Qualität der Kommentare sein kann. Der Kommentar der Funktion `rand` beschreibt die Funktion präzise und knapp. Dagegen verweist der Kommentar von der Funktion `rand_r` nur auf einen ISO-C-Standard. Dadurch liefert der *SentenceTransformer* ungenaue Ergebnisse, denn der Kosinus-Abstand zwischen den Vektoren der Kommentare beträgt $d = 0.8544$. Dagegen beträgt der Kosinus-Abstand von den Code-Llama-Erklärungen der beiden Funktionen $d = 0.2216$.

Code-Llama-Erklärungen. In dieser Arbeit wurde das größte Modell der Code-LLama-Familie mit 70 Milliarden Parametern verwendet, um die Code-Llama-Erklärungen zu erzeugen. Aus diesem Grund ist das gewählte Modell auch das rechenaufwendigste. In zukünftiger Forschung könnten kleinere Modelle mit weniger Rechenaufwand verwendet werden, um die Frage zu beantworten, ob der Rechenaufwand des Code-Llama-Modells mit 70 Milliarden Parametern nötig ist.

Eine weitere Problematik ist die Stabilität von Code Llama. Bei Schwankungen von Code-Llama-Erklärungen kann nicht garantiert werden, dass die Erklärungen in der Praxis bei tatsächlicher Anwendung von gleicher Qualität sind. Deswegen sollte in einer zukünftigen Forschung eine größere Untersuchung, als in dieser Arbeit, über die Stabilität von Large Language-Models durchgeführt werden.

Schließlich könnte in zukünftiger Forschung eine andere Prompt ausprobiert werden, hier könnte bspw. die Prompt von Wang et al. verwendet werden [13]. Dadurch könnten sich die Erklärungen verbessern und damit wieder die Qualität der Embeddings.

Code2Vec. Diese Methodik, Embeddings zu erzeugen, ist abhängig von der Programmiersprache des Datensatzes. Das *Code2Vec*-Modell wurde ursprünglich für Java entwickelt, trotzdem ist es möglich, das Modell mit anderen Programmiersprachen zu verwenden. Für jede neue Sprache ist es erforderlich ein Tool zu schreiben, das die besagte Sprache in das passende *Code2Vec* Input-Format umwandelt. Außerdem ist es notwendig das Modell noch zu trainieren, um danach bei gegebener Funktion einen Vektor zu produzieren. Deswegen kann je nach Datensatz der Aufwand, um die Embeddings zu generieren, hoch sein.

Eine weitere Schwäche ist die Abhängigkeit von der Namensgebung der Funktionen im Datensatz, da das *Code2Vec* Modell darauf trainiert wird, Funktionsnamen vorherzusagen, dadurch entstehen dieselben Probleme wie bei der Diskussion zu den Funktionsnamen.

Des Weiteren könnten die bescheidenen Ergebnisse des *Code2Vec*-Modells anhand der Sprache des Datensatzes, der Qualität der Funktionsnamen im Datensatz oder auch durch die Größe des Datensatzes erklärt werden.

Die CMP Funktion. In dieser Arbeit wurde die CMP-Funktion vorgestellt, welche zwei Datenmengen anhand ihrer Nachbarschaftsbeziehungen vergleicht. Sie berechnet für zwei Datenmengen $A, B \in \mathbb{R}^{N \times l}$ einen Ähnlichkeit-Score $\text{CMP}(A, B, k) = s \in [0, 1] \subset \mathbb{R}$. Dabei ist N die Größe der Datenmengen, l die Dimension der Vektoren in der Datenmenge und k die Anzahl der Nachbarn, die verglichen werden sollen. Analog zum Perplexity-Parameter bei *t-SNE*, sollte k nach der Größe der Gruppierungen in den Datenmengen gewählt werden. Dabei reagiert die Formel wesentlich empfindlicher auf Änderungen von k , als der Perplexity-Parameter in *t-SNE*. In zukünftiger Forschung könnte ein Intervall herausgearbeitet werden $a \leq k \leq b$ mit $a, b \in \mathbb{N}$ oder sogar einen optimalen Wert $k := C \in \mathbb{N}$ für alle Datenmengen. Das ist auch wünschenswert, da die Formel für alle $k = 2, 3, \dots, N$ auszurechnen einen hohen Rechenaufwand darstellt. Das liegt primär an dem K-Nearest-Neighbor-Algorithmus bzw. an einer Funktion, die Nachbarn aufsteigend sortiert nach dem Abstand zu eingegebenen Punkt berechnet. Die restlichen Operationen sind elementare Rechenoperationen. Zunächst könnte man also verschiedene Funktionen ausprobieren, die die Nachbarn aufsteigend nach dem Abstand zum eingegebenen Punkt sortiert.

Das liefert folgende Verallgemeinerung:

Sei $f_k \in \{\mathbb{R}^{N \times l} \times \mathbb{R}^l \rightarrow \mathbb{N}^k\}$ beliebig, mit oben beschriebenen Eigenschaften, dann gilt:

$$CMP(A, B, k) = \frac{1}{N} \sum_{i=1}^N \text{compare}_k(f_k(A_i, A), f_k(B_i, B)).$$

Des Weiteren wurde hier, um die Resultate der Funktion compare_k zu aggregieren, das arithmetische Mittel verwendet. Diese Wahl ist willkürlich und könnte durch eine andere Aggregationsmethode ersetzt werden. Daraus folgt die nächste Verallgemeinerung:

Sei $f_k \in \{\mathbb{R}^{N \times l} \times \mathbb{R}^l \rightarrow \mathbb{N}^k\}$ wie oben und $\text{agg} \in \{\mathcal{P}([0, 1]) \rightarrow [0, 1]\}$ beliebig, dann gilt:

$$CMP(A, B, k) = \text{agg}(\{\text{compare}_k(f_k(A_i, A), f_k(B_i, B)) \mid i = 1, 2, \dots, N\})$$

Die letzte Verallgemeinerung betrifft die score_k funktion.

$$\text{score}_k(l, i, v) = \begin{cases} 1 & , \exists j \in \mathbb{N} : l = v_j \wedge i = j \\ \frac{1}{2} & , \exists j \in \mathbb{N} : l = v_j \wedge i \neq j \\ 0 & , \text{otherwise} \end{cases} \quad \text{und } G_k := \sum_{i=1}^k \frac{1}{\log_2(i+1)}.$$

Der Wert, den die Funktion zurückgibt, wenn der Nachbarindex l in dem Nachbarschaftsverhältnis v enthalten ist, aber nicht auf derselben Position ist, beträgt $\text{score}_k(l, i, v) = \frac{1}{2}$. Dieser ist wiederum völlig willkürlich gewählt. Deswegen wäre hier eine sinnvolle Verallgemeinerung:

Sei $a \in (0, 1) \subset \mathbb{R}$ beliebig, dann gilt:

$$\text{score}_k(l, i, v) = \begin{cases} 1 & , \exists j \in \mathbb{N} : l = v_j \wedge i = j \\ a & , \exists j \in \mathbb{N} : l = v_j \wedge i \neq j \\ 0 & , \text{otherwise} \end{cases} \quad \text{und } G_k := \sum_{i=1}^k \frac{1}{\log_2(i+1)}.$$

All diese Verallgemeinerungen motivieren das Ausprobieren verschiedener Instanzen der verallgemeinerten Objekte. In zukünftiger Forschung könnte herausgefunden werden, welche Vorteile und Nachteile, die verschiedene Instanzen haben.

Code2Vec und BERT als Inspiration für ein neues Modell. Nach meiner Meinung ist das größte Problem von *Code2Vec* die Abhängigkeit von den Funktionsnamen der Trainingsdaten und das überwachte Lernen. Anstatt das Modell darauf zu trainieren, Funktionsnamen vorherzusagen, könnte man mit unüberwachten Lernen, wie in dem BERT-Modell, Trainingsaufgaben geben, welche das Verständnis von Quellcode stärken. Da der Input von *Code2Vec* ein abstrakter Syntaxbaum ist, könnte hier eine Aufgabe sein, ein fehlenden Knoten im Baum vorherzusagen. Eine weitere Trainingsaufgabe könnte sein, ob zwei Zweige in einem abstrakten Syntaxbaum sequenziell hintereinander kommen oder nicht. Dazu könnte man entweder noch das Prinzip von Aufmerksamkeit aus der Transformer-Architektur oder *Code2Vec* übernehmen.

6 Fazit

In dieser Arbeit wurden vier verschiedene Arten vorgestellt, aus C Quellcode reellwertige Vektoren zu produzieren, die den Inhalt der Funktion codieren. Zum einen wurden aus Funktionsnamen, Funktionskommentaren und Code-Llama-Erklärungen, mittels *SentenceTransformer*, Vektoren produziert. Zum anderen wurden aus dem *Code2Vec* Modell, welches auf C adaptiert wurde, die Inferenz-Vektoren entnommen.

Durch eine Expertenbefragung konnte die besten Embeddings identifiziert werden, diese sind aus den Code-Llama-Erklärungen entstanden. Des Weiteren wurde eine quantitative Auswertung durchgeführt, mittels einer Funktion, die eine Datenmengen mit den Code-Llama-Vektoren anhand ihrer Nachbarschaftsbeziehungen vergleicht. Schließlich wurde eine qualitative Evaluierung durchgeführt indem die verschiedenen Embedding-Prozesse durch *t-SNE* in die 2-dimensionalen Ebene projiziert wurde, um diese auf Gruppierungen zu untersuchen. Dabei resultierte, dass die Code-Llama-Erklärungen die Embeddings mit der höchsten Qualität produzieren. Diese sind gefolgt von Funktionsnamen, danach Funktionskommentare und schließlich *Code2Vec*. Wobei im Allgemeinen nicht offensichtlich ist, was ein hochqualitatives Embedding ist, da wiederum nicht klar ist, wie man die semantische Ähnlichkeit zwischen zwei Quellcodeabschnitten Formal definiert.

Die von den Code-Llama-Erklärungen erzeugten Vektoren könnten direkt eingesetzt werden, um viele verschiedene Problemstellungen für die C-Programmiersprache zu lösen.

Die Motivation dieser Arbeit war es aber Vektoren für Neuronales Netzwerk zu generieren, um dieses neuronale Netzwerk, mittels überwachten Lernens darauf zu trainieren, bei gegebener Funktion in Maschinensprache einen Vektor vorherzusagen, der den Inhalt der Funktion codiert. Die resultierenden Vektoren, die den Inhalt des Binärcodes codieren, können dann benutzt werden, um neuronale Netzwerke auf diverse Anwendungen zu trainieren, wie Beispielsweise *Binary Code-Similarity-Detection* [7], *Function-Boundary-Detection* [8], *Function-Type-Inference* [9], *Binary Code-Search* [10], Reverse Engineering [11], oder das Klassifizieren von Maleware in der Maschinensprache [12]. Dieses Neuronales Netzwerk könnte nun mit den Vektoren, welche aus den Code-Llama-Erklärungen erzeugt wurden, trainiert werden.

A t-SNE Graphen




Abbildung A.1: Die *t-SNE* Vektoren, mit unterschiedlichen Perplexity-Parameter, produziert aus den hochdimensionalen *Code2Vec* Vektoren. Die Grafik liefert bei jedem der Perplexity-Parameter ein Indiz dafür, dass die Mathematik- und IO-Funktionen jeweils größtenteils in den hochdimensionalen Daten ein Cluster bilden. Sonst ist keine weitere Gruppierung zu erkennen.




Abbildung A.2: Die *t-SNE* Vektoren, mit unterschiedlichen Perplexity-Parameter, produziert aus den hochdimensionalen Funktionskommentar-Embeddings. Hier gibt es, wie im vorherigen Abschnitt beschrieben, deutlich weniger Punkte als bei den restlichen Strategien, Embeddings zu erzeugen. In den drei Graphen ist eine große Gruppierung in der Kategorie Dateimanagement und kleine Gruppierungen in den Kategorien Mathematik, String und Signale zu erkennen.




Abbildung A.3: Die t -SNE Vektoren, mit unterschiedlichen Perplexity-Parameter, produziert aus den hochdimensionalen Funktionsnamen-Embeddings. In der Abbildung ist zu erkennen, dass die Kategorien Nebenläufigkeit, Speicher, Mathematik und Signale eine Gruppierung bilden. Dagegen teilen sich die Kategorien Netzwerk, IO, String in mehrere Untergruppierungen auf.




Abbildung A.4: Die t -SNE Vektoren, mit unterschiedlichen Perplexity-Parameter, produziert aus den hochdimensionalen Code-Llama-Erklärungen-Embeddings. In der Abbildung ist zu erkennen, dass die Kategorien Nebenläufigkeit, Speicher, Mathematik und Signale eine Gruppierung bilden. Dagegen teilen sich die Kategorien Netzwerk, IO, String in mehrere Untergruppierungen auf.

Literatur

- [1] B. Rozière, J. Gehring, F. Gloeckle, S. Sootla, I. Gat, X. E. Tan, Y. Adi, J. Liu, R. Sauvestre, T. Remez, J. Rapin, A. Kozhevnikov, I. Evtimov, J. Bitton, M. Bhatt, C. C. Ferrer, A. Grattafiori, W. Xiong, A. Défossez, J. Copet, F. Azhar, H. Touvron, L. Martin, N. Usunier, T. Scialom, and G. Synnaeve, “Code Llama: Open Foundation Models for Code,” 2024. [Online]. Available: <https://arxiv.org/abs/2308.12950>
- [2] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 11 2019.
- [3] U. Alon, M. Zilberstein, O. Levy, and E. Yahav, “code2vec: Learning Distributed Representations of Code,” *Proceedings of the ACM on Programming Languages*, vol. 3, no. POPL, p. 1–29, Jan. 2019.
- [4] S. Ballı and O. Karasoy, “Development of content-based SMS classification application by using Word2Vec-based feature extraction,” *IET Software*, vol. 13, no. 4, p. 295–304, Aug. 2019.
- [5] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient Estimation of Word Representations in Vector Space,” in *1st International Conference on Learning Representations, ICLR 2013, Scottsdale, Arizona, USA, May 2-4, 2013, Workshop Track Proceedings*, 2013.
- [6] Y. Wu, M. Schuster, Z. Chen, Q. V. Le, M. Norouzi, W. Macherey, M. Krikun, Y. Cao, Q. Gao, K. Macherey, J. Klingner, A. Shah, M. Johnson, X. Liu, Łukasz Kaiser, S. Gouws, Y. Kato, T. Kudo, H. Kazawa, K. Stevens, G. Kurian, N. Patil, W. Wang, C. Young, J. Smith, J. Riesa, A. Rudnick, O. Vinyals, G. Corrado, M. Hughes, and J. Dean, “Google’s Neural Machine Translation System: Bridging the Gap between Human and Machine Translation,” 2016. [Online]. Available: <https://arxiv.org/abs/1609.08144>
- [7] H. Wang, W. Qu, G. Katz, W. Zhu, Z. Gao, H. Qiu, J. Zhuge, and C. Zhang, “jTrans: Jump-Aware Transformer for Binary Code Similarity Detection,” in *Proceedings of the 31st ACM SIGSOFT International Symposium on Software Testing and Analysis*, ser. ISSTA ’22. ACM, Jul. 2022, p. 1–13.
- [8] E. C. R. Shin, D. Song, and R. Moazzezi, “Recognizing Functions in Binaries with Neural Networks,” in *24th USENIX Security Symposium (USENIX Security 15)*. Washington, D.C.: USENIX Association, Aug. 2015, pp. 611–626.
- [9] Z. L. Chua, S. Shen, P. Saxena, and Z. Liang, “Neural Nets Can Learn Function Type Signatures From Binaries,” in *26th USENIX Security Symposium (USENIX Security 17)*. Vancouver, BC: USENIX Association, Aug. 2017, pp. 99–116.
- [10] J. Yang, C. Fu, X.-Y. Liu, H. Yin, and P. Zhou, “Codee: A Tensor Embedding Scheme for Binary Code Search,” *IEEE Transactions on Software Engineering*, vol. 48, no. 7, pp. 2224–2244, 2022.

- [11] J. Lacomis, P. Yin, E. Schwartz, M. Allamanis, C. Le Goues, G. Neubig, and B. Vasilescu, “DIRE: A Neural Approach to Decompiled Identifier Naming,” in *2019 34th IEEE/ACM International Conference on Automated Software Engineering (ASE)*. Los Alamitos, CA, USA: IEEE Computer Society, Nov. 2019, pp. 628–639.
- [12] E. Raff, J. Barker, J. Sylvester, R. Brandon, B. Catanzaro, and C. K. Nicholas, “Malware Detection by Eating a Whole EXE,” in *The Workshops of the The Thirty-Second AAAI Conference on Artificial Intelligence, New Orleans, Louisiana, USA, February 2-7, 2018*, ser. AAAI Technical Report, vol. WS-18. AAAI Press, 2018, pp. 268–276.
- [13] H. Wang, Z. Gao, C. Zhang, Z. Sha, M. Sun, Y. Zhou, W. Zhu, W. Sun, H. Qiu, and X. Xiao, “CLAP: Learning Transferable Binary Code Representations with Natural Language Supervision,” in *Proceedings of the 33rd ACM SIGSOFT International Symposium on Software Testing and Analysis*, ser. ISSTA ’24. ACM, Sep. 2024, p. 503–515.
- [14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17. Red Hook, NY, USA: Curran Associates Inc., 2017, p. 6000–6010.
- [15] L. van der Maaten and G. Hinton, “Visualizing Data using t-SNE,” *Journal of Machine Learning Research*, vol. 9, no. 86, pp. 2579–2605, 2008.
- [16] R. Kruse, S. Mostaghim, C. Borgelt, C. Braune, and M. Steinbrecher, *Computational Intelligence: A Methodological Introduction*. Springer International Publishing, 2022.
- [17] Y. S. Abu-Mostafa, M. Magdon-Ismail, and H.-T. Lin, *Learning From Data*. AMLBook, 2012.
- [18] M. Wattenberg, F. Viégas, and I. Johnson, “How to Use t-SNE Effectively,” *Distill*, 2016. [Online]. Available: <http://distill.pub/2016/misread-tsne>
- [19] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in *NAACL-HLT (1)*, J. Burstein, C. Doran, and T. Solorio, Eds. Association for Computational Linguistics, 2019, pp. 4171–4186.
- [20] V. Kovalenko, E. Bogomolov, T. Bryksin, and A. Bacchelli, “PathMiner: A Library for Mining of Path-Based Representations of Code,” in *Proceedings of the 16th International Conference on Mining Software Repositories*. IEEE Press, 2019, pp. 13–17.
- [21] M. Astekin, M. Hort, and L. Moonen, “An Exploratory Study on How Non-Determinism in Large Language Models Affects Log Parsing,” in *Proceedings of the ACM/IEEE 2nd International Workshop on Interpretability, Robustness, and Benchmarking in Neural Software Engineering*, ser. InteNSE ’24. New York, NY, USA: Association for Computing Machinery, 2024, p. 13–18.
- [22] K. Järvelin and J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Trans. Inf. Syst.*, vol. 20, no. 4, p. 422–446, Oct. 2002.

- [23] C. Charitsis, C. Piech, and J. C. Mitchell, “Function Names: Quantifying the Relationship Between Identifiers and Their Functionality to Improve Them,” in *Proceedings of the Ninth ACM Conference on Learning @ Scale*, ser. L@S ’22, vol. 28. ACM, Jun. 2022, p. 93–101.
- [24] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave, and G. Lample, “LLaMA: Open and Efficient Foundation Language Models,” 2023. [Online]. Available: <https://arxiv.org/abs/2302.13971>
- [25] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale, D. Bikel, L. Blecher, C. C. Ferrer, M. Chen, G. Cucurull, D. Esiobu, J. Fernandes, J. Fu, W. Fu, B. Fuller, C. Gao, V. Goswami, N. Goyal, A. Hartshorn, S. Hosseini, R. Hou, H. Inan, M. Kardas, V. Kerkez, M. Khabsa, I. Kloumann, A. Korenev, P. S. Koura, M.-A. Lachaux, T. Lavril, J. Lee, D. Liskovich, Y. Lu, Y. Mao, X. Martinet, T. Mihaylov, P. Mishra, I. Molybog, Y. Nie, A. Poulton, J. Reizenstein, R. Rungta, K. Saladi, A. Schelten, R. Silva, E. M. Smith, R. Subramanian, X. E. Tan, B. Tang, R. Taylor, A. Williams, J. X. Kuan, P. Xu, Z. Yan, I. Zarov, Y. Zhang, A. Fan, M. Kambadur, S. Narang, A. Rodriguez, R. Stojnic, S. Edunov, and T. Scialom, “Llama 2: Open Foundation and Fine-Tuned Chat Models,” 2023. [Online]. Available: <https://arxiv.org/abs/2307.09288>